

Interrogación 1

$$Var(x) = E(X^2) - E^2(X)$$

$$M_x(t) = E(e^{tx})$$

Notación CASELLA:

$$\min\{x_i\} = x_{(1)}$$

$$\max\{x_i\} = x_{(n)}$$

$$S^2 = \frac{1}{n-1} \cdot \sum_{i=1}^n (x_i - \bar{X})^2$$

$$S_n^2 = \frac{1}{n} \cdot \sum_{i=1}^n (x_i - \bar{X})^2$$

La **función indicatriz** de un subconjunto A de \mathcal{X} es la función $I: \mathcal{X} \rightarrow \{0,1\}$ dada por:

$$I_A(x) \equiv I(x \in A) = \begin{cases} 1 & \text{si } x \in A \\ 0 & \text{si } x \notin A \end{cases}$$

Para variables aleatorias continuas:

$$E(x) = \int x \cdot f_x(x_i) \cdot dx$$

Para variables aleatorias discretas:

$$E(x) = \sum_{i=0}^{\infty} x_i \cdot f_x(x_i)$$

Si $X_1, \dots, X_n \sim iid$:

$$Var(\bar{X}) = \frac{Var(X)}{n} \quad \wedge \quad E(\bar{X}) = \mu$$

Función de Máxima Verosimilitud:

$$L(\theta|x) = \prod_{i=1}^n f(x_i|\theta)$$

Notar que, para estimar con esta función, se debe derivar respecto al parámetro de interés, e igualar a 0

Definición: Sea $\pi(\theta)$ la distribución *a priori*, y la función distribución de la muestra $f(x|\theta)$, entonces la distribución **posteriori**:

$$\pi(\theta|x) = \frac{f(x|\theta)\pi(\theta)}{m(x)}$$

Recordar:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

Donde $m(x) = \int f(x|\theta)\pi(\theta)d\theta$

Constante de normalización \mathcal{C} es tal que $m(x)$ cumple:

$$\mathcal{C} \cdot m(x) = 1$$

Luego:

$$\pi(\theta|x) \rightarrow \mathcal{C} \cdot \pi(\theta|x)$$

Dado un parámetro θ con función de densidad posteriori $\pi(\theta|x)$, su estimador de Bayes corresponde a:

$$\hat{\theta}_B = E(\theta|x) = \int \theta \cdot \pi(\theta|x) \cdot d\theta$$

Recordar el teorema de cambio de variable univariado (**Teorema 2.1.8 Casella & Berger**): Sea $X \sim f_X(x)$ y sea $Y = g(X)$. Supongamos que existe una partición A_0, A_1, \dots, A_k de \mathcal{X} tal que $P(X \in A_0) = 0$ y $f_X(x)$ es continua en cada A_i . Además, supongamos que existen funciones $g_1(x), \dots, g_k(x)$, definidos en A_1, \dots, A_k , respectivamente, que satisfacen:

- i) $g(x) = g_i(x)$ para $x \in A_i$
- ii) $g_i(x)$ es monótona en cada A_i
- iii) El conjunto $\mathcal{Y} = \{y: y = g_i(x) \text{ para algún } x \in A_i\}$ es el mismo para cada $i = 1, \dots, k$
- iv) $g_i^{-1}(y)$ tiene derivada continua en \mathcal{Y} en cada $i = 1, \dots, k$

Entonces:

$$f_Y(y) = \begin{cases} \sum_{i=1}^k f_X(g_i^{-1}(y)) \left| \frac{d}{dy} g_i^{-1}(y) \right| & y \in \mathcal{Y} \\ 0 & \text{en cualquier otro caso} \end{cases}$$

Estadísticos de Orden y sus distribuciones.

$$f_{X_{(1)}}(x) = n \cdot f(x) \cdot (1 - F(x))^{n-1}$$

$$f_{X_{(n)}}(x) = n \cdot f(x) \cdot (F(x))^{n-1}$$

$$f_{X_{(i)}}(x) = \binom{n}{i} \cdot i \cdot f(x) \cdot (F(x))^{i-1} (1 - F(x))^{n-1}$$

Recordamos que:

$$F(x) = \int_{-\infty}^x f_x(t) \cdot dt$$

Distribución Gamma:

$$\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} \cdot e^{-x} \cdot dx$$

$$\Gamma(n) = (n-1)!$$

Interrogación 2

Definición:

El error cuadrático medio (ECM) de un estimador $T(X)$ de θ corresponde a:

$$\begin{aligned} ECM_{\theta}(T(X)) &= E_{\theta}\{(T(X) - \theta)^2\} \\ &= Var_{\theta}(T(X)) + (\text{Sesgo}_{\theta}T(X))^2 \end{aligned}$$

Donde:

$$\text{Sesgo}_{\theta}T(X) = E(T(X)) - \theta$$

$$\boxed{\text{Sesgo}_{\theta}T(X) = 0} \Rightarrow \boxed{T(X) \text{ es insesgado}}$$

Mejores estimadores insesgados

Un estimador $W(X)$ es un mejor estimador insesgado si y sólo si:

$$E_{\theta}(W(X)) = \tau(\theta),$$

y, para todo estimador $T(X)$ tal que $E_{\theta}(T(X)) = \tau(\theta)$ se cumple que

$$\boxed{Var_{\theta}(W(X)) \leq Var_{\theta}(T(X))}$$

Para todo $\theta \in \Theta$.

El estimador $W(X)$ se dice también insesgado y de varianza uniformemente mínima, o **UMVUE**, de $\tau(\theta)$.

Teorema de Cramér-Rao:

Sea X_1, \dots, X_n una muestra con función de densidad conjunta $f_{\theta}(x)$, y $T(X)$ un estimador tal que $E_{\theta}(T(X))$ es diferenciable como función de θ . Suponga que la densidad de X satisface:

$$\frac{d}{d\theta} \int \cdots \int h(x) f_{\theta}(x) dx = \int \cdots \int h(x) \cdot \frac{d}{d\theta} f_{\theta}(x) dx$$

para toda función h con $E_{\theta}|h(\mathbf{x})| < \infty$. Entonces:

$$Var_{\theta}(T(\mathbf{X})) \geq \frac{\left(\frac{d}{d\theta} E_{\theta}(T(\mathbf{X}))\right)^2}{E_{\theta}\left(\left(\frac{d}{d\theta} \log f_{\theta}(\mathbf{X})\right)^2\right)}$$

Corolario:

Sea $\mathbf{X}_1, \dots, \mathbf{X}_n$ una muestra aleatoria proveniente de una distribución con función de densidad $f_{\theta}(x)$, y sea $T(\mathbf{X})$ un estimador donde $E_{\theta}(T(\mathbf{X}))$ es diferenciable como función de θ . Si la densidad conjunta $\prod_{i=1}^n f_{\theta}(x_i)$ cumple las condiciones del *Teorema de Cramér-Rao*, entonces:

$$Var_{\theta}(T(\mathbf{X})) \geq \frac{\left(\frac{d}{d\theta} E_{\theta}(T(\mathbf{X}))\right)^2}{n \cdot E_{\theta}\left(\left(\frac{d}{d\theta} \log f_{\theta}(\mathbf{X})\right)^2\right)}$$

Teorema:

Si $f_{\theta}(x)$ satisface:

$$\frac{d}{d\theta} \int \left(\frac{\partial}{\partial \theta} \log f_{\theta}(x)\right) f_{\theta}(x) dx = \int \frac{\partial}{\partial \theta} \left[\left(\frac{\partial}{\partial \theta} \log f_{\theta}(x)\right) f_{\theta}(x)\right] dx$$

entonces:

$$E_{\theta}\left(\left(\frac{\partial}{\partial \theta} \log f_{\theta}(\mathbf{X})\right)^2\right) = -E_{\theta}\left(\frac{\partial^2}{\partial \theta^2} \log f_{\theta}(\mathbf{X})\right)$$

Familia Exponencial

Consideremos una familia de distribuciones indexadas por el parámetro θ ,

$$\mathcal{P} = \{P_{\theta}: \theta \in \Theta\},$$

para una variable aleatoria X , que toma valores en \mathcal{X} con función de verosimilitud asociada $L(x, \cdot)$. Se dice que la log-verosimilitud de X pertenece a una **familia exponencial** si y sólo si:

- Existe un conjunto S , que no depende del valor de θ , tal que:

$$P_{\theta}(X \in S) = 1, \quad \forall \theta \in \Theta$$

y

$$f_{\theta}(x) > 0, \quad \forall x \in S$$

En otras palabras, existe un conjunto de posibles valores que puede tomar x (\mathbb{N}, \mathbb{R} , etc.) donde este conjunto NO depende del valor de θ .

Donde $f_{\theta}(\cdot)$ corresponde a la función densidad asociada a P_{θ} .

- Existen funciones $\omega_1, \dots, \omega_n$, con dominio Θ y t_1, \dots, t_k , con dominio \mathcal{X} , todas ellas real valoradas, tales que:

$$\log L(x, \theta) = \log h(x) + \log c(\theta) + \sum_{j=1}^k \omega_j(\theta) t_j(x)$$

con h, c funciones positivas, real valoradas.

Equivalentemente, según *Casella & Berger*, una densidad es pertenece a una familia exponencial si puede escribirse como:

$$f_{\theta}(x) = h(x)c(\theta) \exp \left\{ \sum_{i=1}^k w_i(\theta) t_i(x) \right\}$$

Importante: Si una distribución constituye una familia exponencial, entonces se cumplen las condiciones del teorema de *Cramér-Rao*.

Principio de suficiencia:

Si $T(\mathbf{X})$ es un estadístico suficiente para θ , inferencia sobre este parámetro debe ser hecha solo sobre la base e $T(\mathbf{X})$.

Estadístico suficiente:

Un estadístico $T(\mathbf{X})$ es un estadístico suficiente para θ , si y sólo si **la distribución condicional de la muestra \mathbf{X} dado el valor de $T(\mathbf{X})$ NO depende e θ** .

Teorema:

Sea f_θ la función densidad conjunta de X_1, \dots, X_n . El estadístico $T(\mathbf{X})$, con distribución q_θ , es suficiente para θ si y sólo si la razón

$$\frac{f_\theta(x)}{q_\theta(T(x))} \quad \text{NO depende de } \theta$$

es constante como función de θ , para todo valor de $x \in \mathcal{X}$.

Teorema de factorización (Fisher-Neyman):

Sea $f_\theta(x)$ la función de densidad (probabilidad) conjunta de la muestra \mathbf{X} . Un estadístico $T(\mathbf{X})$ es un estadístico suficiente para θ , si y sólo si existen funciones g_θ y h , tales que, para todo $x \in \mathcal{X}$ y $\theta \in \Theta$,

$$f_\theta(x) = g_\theta(T(x)) \cdot h(x)$$


Resultado:

Suponga que $T(\mathbf{X})$ es un estadístico suficiente para θ , y defina el estadístico:

$$T'(\mathbf{X}) = r \cdot (T(\mathbf{X})),$$

con r una función **inyectiva**. Entonces, el estadístico $T'(\mathbf{X})$ también corresponde a un estadístico suficiente para θ .

Recordar:



Suficiencia en una familia exponencial:

Sea X_1, \dots, X_n una muestra aleatoria proveniente de una distribución en una familia exponencial, con densidad (probabilidad) f_θ , de modo que:

$$f_\theta(x) = h(x) \cdot c(x) \cdot \exp \left\{ \sum_{j=1}^k \omega_j(\theta) \cdot t_j(x) \right\}$$

Entonces,

$$T(\mathbf{X}) = \left(\sum_{i=1}^n t_1(x_i), \dots, \sum_{i=1}^n t_k(x_i) \right)$$

es un estadístico suficiente para θ .

Estadístico suficiente minimal:

Un estadístico suficiente $T(\mathbf{X})$ se dice suficiente minimal, si y sólo si para cualquier otro estadístico suficiente $T'(\mathbf{X})$, existe una función v , tal que:

$$T(\mathbf{X}) = v(T'(\mathbf{X}))$$

Teorema sobre minimalidad:

Sea f_θ la función de densidad (probabilidad) de una muestra aleatoria X_1, \dots, X_n . Si se cumple que:

$$\frac{f_\theta(x)}{f_\theta(y)} \text{ No depende de } \theta \iff T(x) = T(y)$$

Entonces:

$T(\mathbf{X})$ es suficiente minimal para θ .

Interrogación 3

Estadístico Ancilar:

Un estadístico $S(\mathbf{X})$ se denomina ancilar para un parámetro θ si y sólo si su distribución NO depende de este parámetro.

Ejercicio:

Sea X_1, \dots, X_n una muestra aleatoria proveniente de una distribución Uniforme($\theta, \theta + 1$), con $\theta \in \mathbb{R}$. Muestre que el rango:

$$R(\mathbf{X}) = X_{(n)} - X_{(1)}$$

es ancilar para θ .

Solución:

Es fácil ver que el rango de la uniforme será $(\theta + 1) - (\theta) = 1$ y, por lo tanto, no dependerá de θ y el rango será ancilar. Sin embargo, lo demostraremos por definición:

Sea $X_1, \dots, X_n \sim iid$, con $x_{(i)}, x_{(j)}$ estadísticos de orden, la función de distribución será:

$$f_{x_{(i)}, x_{(j)}}(u, v) = \frac{n!}{(i-1)!(j-1-i)!(n-j)!} \cdot f_x(u) \cdot f_x(v) \cdot [F_x(u)]^{i-1} \cdot [F_x(v) - F_x(u)]^{j-1-i} \cdot [1 - F_x(v)]^{n-j} \cdot I(-\infty < u < v < \infty)$$

Ahora, necesitamos que $i = 1$ y $j = n$, dado que eso estamos buscando.

Las funciones f_x y F_x serán, respectivamente:

$$f_x(x) = \frac{1}{\theta + 1 - \theta} \cdot I(\theta < x < \theta + 1) = I(\theta < x < \theta + 1)$$

$$F_x(x) = P(X \leq x) = \begin{cases} 0 & , \quad x \leq \theta \\ x - \theta & , \quad \theta < x < \theta + 1 \\ 1 & , \quad x \geq \theta + 1. \end{cases}$$

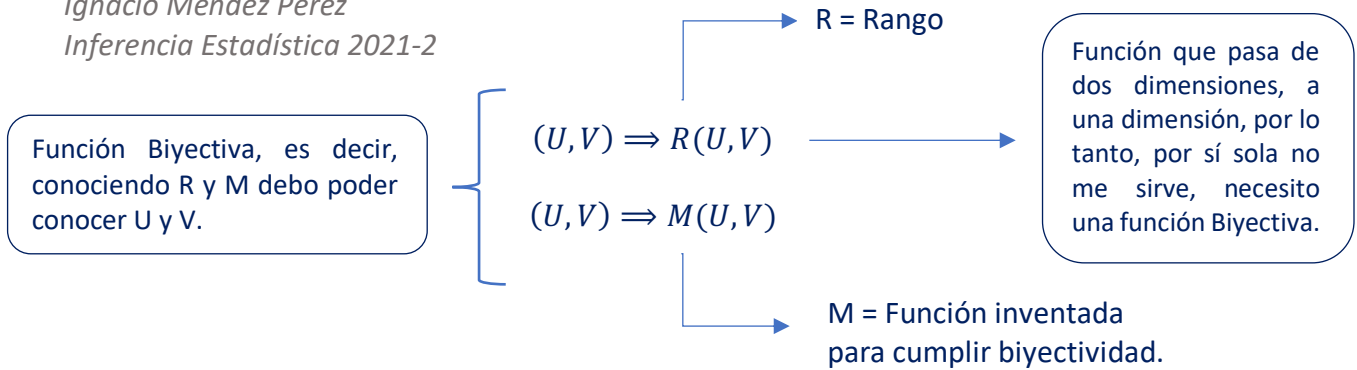
Revisar guía distribuciones

Reemplazamos al caso general y nos queda:

$$f_{x_{(1)}, x_{(n)}}(u, v) = n(n-1)(v-u)^{n-2} \cdot I(\theta < u < v < \theta + 1)$$

Queremos la distribución de $R(\mathbf{X}) = X_{(n)} - X_{(1)}$.

Sean U y V dos variables aleatorias:



$$(u, v) \Rightarrow (r, m)$$

$$\left. \begin{array}{l} u = g_u^{-1}(r, m) \\ v = g_v^{-1}(r, m) \end{array} \right\} \text{ Funciones que me permiten conocer los valores de } u \text{ y } v \text{ conociendo } r \text{ y } m.$$

Teorema del Jacobiano:

“Derivadas parciales de las variables antiguas (u, v) con respecto a las nuevas (r, m) ”

$$J = \begin{pmatrix} \frac{\partial u}{\partial r} & \frac{\partial u}{\partial m} \\ \frac{\partial v}{\partial r} & \frac{\partial v}{\partial m} \end{pmatrix}$$

$$f_{R,M}(r, m) = |\det(J)| \cdot \underbrace{f_{U,V}(u, v)}_{\text{de } x_{(1)}, x_{(n)}}$$

Propuesta:

$$R = X_{(n)} - X_{(1)}$$

$$M = \frac{X_{(1)} + X_{(n)}}{2}$$

$$\begin{array}{l} U = X_{(1)} \\ V = X_{(n)} \end{array}$$

$$(x_{(1)}, x_{(n)}) \Rightarrow (r, m)$$

$$\underbrace{x_{(1)} = \frac{2m - r}{2}}_{g_u^{-1}(r, m)} \wedge \underbrace{x_{(n)} = \frac{2m + r}{2}}_{g_v^{-1}(r, m)}$$

$$J = \begin{pmatrix} \frac{\partial x_{(1)}}{\partial r} & \frac{\partial x_{(1)}}{\partial m} \\ \frac{\partial x_{(n)}}{\partial r} & \frac{\partial x_{(n)}}{\partial m} \end{pmatrix} = \begin{pmatrix} -\frac{1}{2} & 1 \\ \frac{1}{2} & 1 \end{pmatrix} \Rightarrow \det(J) = -1$$

$$|\det(J)| = 1$$

Luego,


$$f_{R,M}(r, m) = \underbrace{|\det(J)|}_1 \cdot \underbrace{f_{U,V}(u, v)}_{\text{de } x_{(1)}, x_{(n)}} \\ = n(n-1)(v-u)^{n-2} \cdot I(-\infty < u < v < \infty)$$

$$\left. \begin{aligned} u &= \frac{2m-r}{2} \\ v &= \frac{2m+r}{2} \end{aligned} \right\} v-u = \frac{r}{2} + \frac{r}{2} = r$$

$$= n(n-1)r^{n-2} \cdot I\left(\theta < \frac{2m-r}{2} < \frac{2m+r}{2} < \theta+1\right)$$

Como vemos, necesitamos que $r > 0$ para que se cumpla lo de la indicatriz.

Ahora, si despejamos m en ambos lados de la indicatriz, tenemos que:



¿Qué valores puede tomar r además de ser positiva?

$$\theta + \frac{r}{2} < \theta + 1 - \frac{r}{2}$$

$$0 < r < 1$$

→ 2^{da} condición

Entonces nos queda:

$$f_{R,M}(r, m) = n(n-1)r^{n-2} \cdot I(0 < r < 1) \cdot I\left(\theta + \frac{r}{2} < m < \theta + 1 - \frac{r}{2}\right)$$

$$f_R(r) = \int f_{R,M}(r, m) \cdot dm$$

Tomado $0 < r < 1$:

1^{era} condición

2^{da} condición

$$f_R(r) = \int_{\theta + \frac{r}{2}}^{\theta + 1 - \frac{r}{2}} n(n-1)r^{n-2} \cdot dm$$

$$= n(n-1)r^{n-1} \cdot \left(\left(\theta + 1 - \frac{r}{2} \right) - \left(\theta + \frac{r}{2} \right) \right)$$

$$= n(n-1)r^{n-1}(1-r)$$

Luego, $f_R(r) = n(n-1)r^{n-1}(1-r) \cdot I(0 < r < 1)$, NO depende de θ , luego:

$$R = X_{(n)} - X_{(1)}$$

Es ancilar para θ . Entonces, el rango no aporta información sobre θ .

Dependencia entre un estadístico suficiente minimal y uno ancilar:

Considere una muestra aleatoria X_1, \dots, X_n proveniente de una distribución con función de probabilidad dada por:

$$P_\theta(X = \theta) = P_\theta(X = \theta + 1) = P_\theta(X = \theta + 2) = \frac{1}{3},$$


$\therefore \in$ a una Familia de localización, al no depender de θ .

con θ valor desconocido. Considere el estadístico:

$$T(X) = (R(X), M(X)) = \left(X_{(2)} - X_{(1)}, \frac{X_{(1)} + X_{(2)}}{2} \right).$$

Sabemos que $R(X)$ es ancilar para θ (1), y se puede demostrar que $T(X)$ es suficiente minimal (2). Claramente ellos no son independientes.

1) $R(X)$ es ancilar:



Recordatorio:
Ancilaridad en
página 8.

$$P(X = \theta) = P(X = \theta + 1) = P(X = \theta + 2) = \frac{1}{3}$$

$$P(X - \theta = 0) = P(X - \theta = 1) = P(X - \theta = 2) = \frac{1}{3}$$

⇒ Familia de probabilidad es de localización. Entonces, por ejercicio propuesto (pág. 8):

$R(\mathbf{X}) = X_{(n)} - X_{(1)}$ es ancilar para θ .

2) $T(\mathbf{X})$ es suficiente:

$$\begin{aligned} X_{(2)} - X_{(1)} &= r \\ X_{(1)} + X_{(2)} &= 2m \end{aligned}$$

Luego:

$$X_{(2)} = \frac{2m + r}{2} \quad \wedge \quad X_{(1)} = \frac{2m - r}{2} //$$

Estadístico completo:

Sea f_{θ} una familia de funciones de densidad (probabilidad) para un estadístico $T(\mathbf{X})$. La familia f_{θ} se dice una familia completa si y sólo si, para toda función g ,

$$E_{\theta} (g(T(\mathbf{X}))) = 0, \quad \forall \theta \in \Theta$$

si y sólo si:

$$P_{\theta}(g(T(\mathbf{X})) = 0) = 1, \quad \forall \theta \in \Theta$$

Es decir, $g(T(\mathbf{X}))$ tiene que ser 0.

En este caso, también se dice que el estadístico $T(\mathbf{X})$ es un estadístico completo.

Esta idea suele leerse, también, como: “El único estimados insesgado (pág. 3) del cero es el mismo cero”.

Ejercicio:

Considere un estadístico T , con distribución Binomial(n, θ), $0 < \theta < 1$. Muestre que T corresponde a un estadístico completo.

Solución:

Primero, tenemos que llegar a un estadístico que distribuya binomial. Sabemos que dado $X \sim \text{Bernoulli}(\theta)$, entonces $\sum x_i \sim \text{Binomial}(n, \theta)$. Entonces probamos sacando un estadístico de Bernoulli:

$$x_1, \dots, x_n \sim \text{Bernoulli}(\theta)$$

$$\begin{aligned} f_{\theta}(x) &= \theta^{\sum x_i} \cdot (1 - \theta)^{n - \sum x_i} \\ &= \left(\frac{\theta}{1 - \theta} \right)^{\sum x_i} \cdot (1 - \theta)^n \end{aligned}$$

Luego, por teorema de factorización (pág. 6):

$$T(X) = \sum x_i$$

y distribuye $\text{Binomial}(n, \theta)$.

Ahora, T será completo si y sólo si $\forall g$ se tiene que

$$E_{\theta}(g(T)) = 0$$

si y sólo si:

$$g(T) = 0 \quad \forall \theta$$

Tomamos g arbitrario tal que:

$$E_{\theta}(g(T)) = 0$$

si y sólo si:

$$\sum_{t=0}^n g(t) \cdot P_{\theta}(T(X) = t) = 0$$



Por definición de Esperanza Matemática

$$E[X] = \begin{cases} \sum_{i=1}^n X_i P(X_i) & \text{si } X \text{ es una Variable Aleatoria Discreta} \\ \int_{-\infty}^{+\infty} X_i f(X_i) dx & \text{si } X \text{ es una Variable Aleatoria Continua} \end{cases}$$

$$\sum_{t=0}^n g(t) \binom{n}{t} \theta^t (1 - \theta)^{n-t} = 0$$

$$T(X) \sim \text{Binomial}(n, \theta)$$

$$(1 - \theta)^n \sum_{t=0}^n g(t) \binom{n}{t} \left(\frac{\theta}{1 - \theta} \right)^t = 0$$

Ahora, como θ no puede tomar el valor de 1 ($0 < \theta < 1$), se tiene que cumplir que la sumatoria sea igual a 0.

$$\sum_{t=0}^n g(t) \binom{n}{t} (r)^t = 0$$

$$r = \frac{\theta}{1 - \theta}$$

$$g(0) \binom{n}{0} r^0 + g(1) \binom{n}{1} r^1 + \cdots + g(n) \binom{n}{n} r^n, \quad \forall \theta \rightarrow \forall r$$

Entonces todos mis coeficientes por separado tienen que ser igual a 0.

Como las combinatorias nunca serán 0, se tiene que cumplir que $g(t) = 0, \forall t$.

Dicho de otra manera:

$$P_{\theta}(g(T) = 0) = 1$$

Y, por lo tanto, se cumple la condición de completitud.

Teorema de Basú

Sea $T(\mathbf{X})$ un estadístico suficiente minimal (pág. 7) y completo (pág. 12). Entonces $T(\mathbf{X})$ es independiente de todo estadístico ancilar $S(\mathbf{X})$ (pág. 8).

Completitud en Familia exponencial

Sea X_1, \dots, X_n una muestra aleatoria proveniente de una distribución en una familia exponencial, con función de densidad (probabilidad) dada por:

$$f_{\theta}(x) = h(x) \cdot c(\theta) \cdot \exp \left\{ \sum_{j=1}^k \omega_j(\theta) \cdot t_j(x) \right\},$$

donde $\theta = (\theta_1, \dots, \theta_k)$. Si el conjunto $\{(\omega_1(\theta), \dots, \omega_k(\theta)) : \theta \in \Theta\}$ contiene un conjunto abierto en \mathbb{R}^k , entonces, el estadístico:

$$T(\mathbf{X}) = \left(\sum_{i=1}^n t_1(X_i), \dots, \sum_{i=1}^n t_k(X_i) \right)$$

es completo.

Ejercicio:

Sea X_1, \dots, X_n una muestra aleatoria proveniente de una distribución Normal(μ, σ^2), con σ conocido. Muestre que los estadísticos S^2 y \bar{X} son independientes, donde:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \quad \wedge \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Solución:

Utilizaremos el argumento de Basú.

Sabemos que Normal(μ, σ^2) con σ conocido es una familia exponencial (pág. 4). Debemos encontrar las $\omega_1, \dots, \omega_k$ para revisar si sus valores posibles constituyen un conjunto abierto en \mathbb{R}^k .

Revisar pág. 5

$$f_{\mu}(x) = \left(\frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left\{ -\frac{1}{2\sigma^2} (x^2 - \underline{2x\mu} + \mu^2) \right\}$$

$$h(x) = \left(\frac{1}{2\pi\sigma^2} \right)^{1/2} \exp \left\{ -\frac{1}{2\sigma^2} x^2 \right\}$$

$$c(\mu) = \exp \left\{ -\frac{1}{2\sigma^2} \mu^2 \right\}$$

$$\underline{\omega_1(\mu) \cdot t_1(x) = \frac{\mu}{\sigma^2} \cdot x}$$

Y como $\mu \in \mathbb{R}$, entonces $\frac{\mu}{\sigma^2} \in \mathbb{R}$. Como \mathbb{R} es abierto, se cumple la condición de Basú.

Ahora, por una parte, sabemos que:

1. $T(\mathbf{X}) = \bar{X}$ es suficiente minimal (pág. 7).
2. S^2 es ancilar (En toda familia de localización, al igual que el rango, S^2 es ancilar (pág. 8) para μ).

$$\Rightarrow T(\mathbf{X}) \perp S^2$$

$$\bar{X} \perp S^2$$

\perp = Independiente

“Un abierto es un conjunto, donde dado un punto, yo siempre me puedo abrir un poquito”.

La condición es que los valores posibles de $\omega(\mu)$ formen un abierto.

$$\omega(\mu) = \frac{\mu}{\sigma^2}$$

Los valores posibles de μ son los posibles de $\mathbb{R} \rightarrow$ Pasa lo mismo con μ/σ^2 .

Equivarianza frente a cambio de escala de medición:

El principio de Equivarianza bajo cambio de escala de medición indica que las inferencias basadas en observaciones que solo difieren en su escala de medida deben ser idénticas.

Equivarianza (invarianza) formal:

El principio de Equivarianza formal dice que, si asociamos a dos problemas un mismo modelo matemático, entonces debemos utilizar el mismo procedimiento de inferencia en ambos casos.

Principio de Equivarianza

Sea $Y = g(X)$ un cambio de escala en la medición de la variable aleatoria X , tal que los modelos formales para Y y X son los mismos. El principio de equivarianza exige, simultáneamente, el principio de equivarianza bajo cambio de escala de medición y el principio de equivarianza (invarianza) formal.

Ejercicio:

Considere una variable aleatoria X con distribución Binomial(n, θ), y la transformación:

$$Y = g(X) = n - X$$

Para cada uno de los siguientes estadísticos, estudie si cumple con el principio de equivarianza.

- $T_1(X) = X/n$
- $T_2(X) = \frac{9}{10} \frac{X}{n} + \frac{1}{20}$
- $T_3(X) = \frac{8}{10} \frac{X}{n} + \frac{2}{10}$

Solución:

Sea

$$X \sim \text{Binomial}(n, \theta)$$

Buscamos estimadores de θ que cumplan con el principio de equivarianza, bajo la transformación $Y = g(X) = n - X$.

$Y = n - X$ = número de fracasos, por eso, la Binomial de Y tendrá como segundo parámetro el $1 - \theta$, donde θ es la probabilidad de éxito.

$$X \sim \text{Binomial}(n, \theta) \Rightarrow Y \sim \text{Binomial}(n, \delta), \text{ con } \delta = 1 - \theta$$

1) Equivarianza bajo cambio de escala

$$\begin{aligned} \hat{\theta} &= T(X) & \hat{\delta} &= T^*(Y) \\ & & \widehat{1 - \theta} &= T^*(Y) \\ & & \hat{\theta} &= 1 - T^*(Y) \end{aligned}$$

El concepto dice que:

$$\begin{aligned} T(X) &= 1 - T^*(Y) \\ &= 1 - T^*(n - X) \end{aligned} \quad (1)$$

2) Como ambos tienen distribuciones binomiales, entonces tienen el mismo modelo matemático (condición de equivarianza formal).

$$T(X) \Rightarrow T^* = T$$

En (1):

$$\boxed{T(X) = 1 - T(n - x)}$$

Esta sería la condición para cualquier estadístico que cumple el principio de equivarianza.

Propuesta 1:

$$T(X) = \frac{X}{n}$$

$x \in \{0, 1, \dots, n\}$.

Lado izquierdo de la condición:

$$T_1(X) = \frac{X}{n}$$

Lado derecho de la condición:

$$1 - T_1(n - X) = 1 - \frac{n - X}{n} = \frac{X}{n} = T_1(X)$$

\therefore Si cumple.

Propuesta 2:

Lado izquierdo:

$$T_2(X) = \frac{9}{10} \frac{X}{n} + \frac{1}{20}$$

Lado derecho:

$$\begin{aligned} &= 1 - \left(\frac{9}{10} \frac{n - X}{n} + \frac{1}{20} \right) \\ &= \frac{9}{10} \frac{X}{n} + \frac{1}{20} = T_2(X) \end{aligned}$$

\therefore Si cumple.

Propuesta 3:

Lado izquierdo:

$$T_3(X) = \frac{8}{10} \frac{X}{n} + \frac{2}{20}$$

Lado derecho:

$$\begin{aligned} &= 1 - \left(\frac{8}{10} \frac{n - X}{n} + \frac{2}{20} \right) \\ &= \frac{8}{10} \frac{X}{n} \neq T_3(X) \end{aligned}$$

\therefore NO cumple.

Grupos de transformaciones

Un conjunto de funciones, $\{g(x), g \in \mathcal{G}\}$, con dominio y recorrido el espacio muestral \mathcal{X} , se dice un grupo de transformaciones de \mathcal{X} si y sólo si cumple:

- i. Inverso: Para toda función $g \in \mathcal{G}$, existe una función $g' \in \mathcal{G}$ tal que:

$$g'(g(x)) = x, \quad \forall x \in \mathcal{X}$$

- ii. Composición: Para cada par de funciones g y $g' \in \mathcal{G}$, existe una función $g'' \in \mathcal{G}$ tal que:

$$g'(g(x)) = g''(x), \quad \forall x \in \mathcal{X}$$

- iii. Identidad: La función identidad, $g(x) = x, x \in \mathcal{X}$ está en \mathcal{G} .

Invarianza de una familia de modelos bajo un grupo de transformaciones

Sea:

$$\mathcal{F} = \{f_{\theta}(x); \theta \in \Theta\}$$

un conjunto de funciones de densidad (probabilidad) para una variable aleatoria X , y sea \mathcal{g} un grupo de transformaciones del espacio muestral \mathcal{X} . Entonces el conjunto \mathcal{F} es invariante bajo el grupo \mathcal{g} si y sólo si para todo $\theta \in \Theta$ y $g \in \mathcal{g}$, existe un único valor $\theta' \in \Theta$ tal que:

$$Y = g(X)$$

tiene distribución $f_{\theta'}(y)$, cuando X tiene distribución $f_{\theta}(x)$.

Ejercicio:

Considere la familia de distribuciones \mathcal{F} para una muestra aleatoria \mathbf{X} de una población con distribución Normal(μ, σ^2), $\mu \in \mathbb{R}, \sigma \in \mathbb{R}^+$. Muestre que \mathcal{F} es invariante bajo el grupo de transformaciones $\mathcal{g} = \{g_a(x) = x + a, a \in \mathbb{R}\}$.

Solución:

$$\mathcal{F} = \left\{ f_{\theta}(x) = (2\pi\sigma^2)^{-\frac{n}{2}} \cdot \exp\left\{-\frac{1}{2\sigma^2} \sum (x_i - \mu)^2\right\}, \mathbf{u} \in \mathbb{R} \times \mathbb{R}^+ \right\}$$

Con \mathbf{u} = Espacio paramétrico.

$$\theta = (\mu, \sigma^2)$$

$$\mathcal{g} = \{g_a(x) \mid g_a(x) = x + a = (x_1 + a, \dots, x_n + a), a \in \mathbb{R}\}$$

Previo

- 1) g_a es inverso de $g - a$, $\forall a \in \mathbb{R}$.
- 2) $(g_a \circ g_b)(x) = g_a(x + b) = x + (a + b) = g_{a+b}(x)$, $a + b \in \mathbb{R}$.
- 3) Identidad: $a = 0$.

Por lo tanto, \mathcal{g} es un grupo de transformaciones.

Ahora,

$$X \sim \text{Normal}(\mu, \sigma^2) \Rightarrow X + a \sim \text{Normal}(\mu + a, \sigma^2)$$

$$f_{\theta'}(y) = (2\pi\sigma^2)^{-n/2} \cdot \exp\left\{-\frac{1}{2\sigma^2}(y_i - \mu')^2\right\}$$

Donde $\mu' = \mu + a$

$$\theta' = (\mu', \sigma' = \sigma) \in \mathbb{R} \times \mathbb{R}^+$$

Y la distribución de $X + a \in \mathcal{F}$.

Entonces, \mathcal{F} es invariante bajo \mathcal{g} .

Ejercicio:

Suponga que, en el ejercicio anterior, se desea estimar μ .

1. Encuentre características que debe tener un estadístico para cumplir con el principio de equivarianza.
2. Estudie si el estadístico $T_1(\mathbf{X}) = \bar{X}$ cumple con dicho principio.
3. Repita para $T_2(\mathbf{X}) = \frac{1}{2}(X_{(1)} + X_{(n)})$.

Solución:

1)

$$\mathcal{g} = \{g_a(x), a \in \mathbb{R}\}$$

$$\mathcal{F} = \{(Normal(\mu, \sigma^2) \times \cdots \times Normal(\mu, \sigma^2), (\mu, \sigma^2) \in \mathbb{R} \times \mathbb{R}^+\}$$

- I. Equivarianza bajo transformación $g_a \in \mathcal{g}$.

$$\mathbf{X} \sim Normal_n(\mu \perp, \sigma^2 \cdot I) \rightarrow \hat{\mu} = T(\mathbf{X})$$

\perp = Vector de 1s

$$\mathbf{Y} = g_a(x), \quad a \in \mathbb{R}$$

I = Identidad.

$$\mathbf{Y} \sim Normal_n((\mu + a) \perp, \sigma^2 \cdot I) \rightarrow \widehat{\mu + a} = T^*(\mathbf{Y})$$

$$\hat{\mu} = Y^*(\mathbf{Y})$$

Buscamos igualar los $\hat{\mu}$:

$$\boxed{T(\mathbf{X}) = T^*(\mathbf{Y}) - a}$$

II. Equivarianza formal $T = T^*$.

$$\begin{aligned} T(\mathbf{X}) &= T(\mathbf{Y}) - a \\ T(\mathbf{X}) &= T(\mathbf{X} + a) - a \end{aligned}$$

Entonces $\forall \mathbf{x} \in \mathbb{R}^n$:

$$\boxed{T(\mathbf{X}) = T(\mathbf{X} + a) - a}$$

2) \bar{X}

Lado izquierdo de la condición:

$$T(\mathbf{X}) = \bar{X}$$

Lado derecho de la condición:

$$\begin{aligned} T(\mathbf{X} - a) - a &= \overline{\mathbf{X} + a} - a \\ &= \bar{X} + a - a \\ &= \bar{X} \end{aligned}$$

$\therefore \bar{X}$ cumple con el principio de equivarianza bajo \mathcal{g} .

3)

Lado izquierdo de la condición:

$$T(\mathbf{X}) = \frac{1}{2}(x_{(1)} + x_{(n)})$$

Lado derecho de la condición:

$$\begin{aligned} T(\mathbf{X} + a) - a &= \frac{1}{2}(y_{(1)} + y_{(n)}) - a \\ &= \frac{1}{2}((x_{(1)} + a) + (x_{(n)} + a)) - a \\ &= \frac{1}{2}(x_{(1)} + x_{(n)}) \end{aligned}$$

$$\boxed{y = \mathbf{X} + a}$$

$\therefore \frac{1}{2}(x_{(1)} + x_{(2)})$ cumple con el principio de equivarianza bajo \mathcal{g} .

Estimación Intervalar:

Una estimación intervalar para un parámetro real valorado θ corresponde a cualquier par de funciones $L(x_1, \dots, x_n)$ y $U(x_1, \dots, x_n)$ de una muestra x , que satisface:

$$L(x) \leq U(x)$$

para todo $x \in \mathcal{X}$. El intervalo aleatorio $[L(\mathbf{X}), U(\mathbf{X})]$ se denomina un estimador intervalar para θ .

Probabilidad de cobertura:

Para un estimador intervalar $[L(X), U(X)]$ de un parámetro θ , se define su probabilidad de cobertura como la probabilidad de contener al verdadero valor de θ , es decir:

$$P_{\theta}(\theta \in [L(X), U(X)])$$

o, dicho de otra manera:

$$P_{\theta}((L(X) \leq \theta) \cap (U(X) \geq \theta))$$

donde $L(X)$ y $U(X)$ son aleatorios.

Ejercicio:

Sea X_1, \dots, X_n una muestra aleatoria proveniente de una distribución Uniforme(0, θ). Suponga que interesa saber un intervalo de confianza para θ , y se proponen los intervalos:

- (1) $[aX_{(n)}, bX_{(n)}]$, $1 \leq a \leq b$
- (2) $[X_{(n)} + c, X_{(n)} + d]$, $0 \leq c \leq d$

Obtenga la probabilidad de cobertura de cada uno de los intervalos propuestos.

Solución Intervalo (1):

$$X_1, \dots, X_n \sim \text{Uniforme}(0, \theta)$$

Tomamos a, b fijos, con $1 \leq a \leq b$.

$$\begin{aligned} & P_{\theta}(aX_{(n)} \leq \theta \leq bX_{(n)}) \\ &= P_{\theta}\left(a \leq \frac{\theta}{X_{(n)}} \leq b\right) \\ &= P_{\theta}\left(b \leq \frac{X_{(n)}}{\theta} \leq a\right) \\ &= P_{\theta}\left(\frac{\theta}{b} \leq X_{(n)} \leq \frac{\theta}{a}\right) \\ &= P_{\theta}\left(X_{(n)} \leq \frac{\theta}{a}\right) - P_{\theta}\left(X_{(n)} \leq \frac{\theta}{b}\right) = F_{X_{(n)}}\left(\frac{\theta}{a}\right) - F_{X_{(n)}}\left(\frac{\theta}{b}\right) \end{aligned}$$


Probabilidad
de cobertura

Sea

$$F_{X_{(n)}}(x) = P_{\theta}(X_{(n)} \leq x) = P_{\theta}(X_1 \leq x, \dots, X_n \leq x)$$

$$= \prod_{i=1}^n P_{\theta}(X_i \leq x) = \prod_{i=1}^n x \cdot \frac{1}{\theta} = \left(\frac{x}{\theta}\right)^n$$

Como es Uniforme(0, θ):



Entonces, $P(X_i \leq x)$
tiene que ser $x \cdot \frac{1}{\theta}$

Ahora, retomando:

$$\begin{aligned} &= P_{\theta}\left(X_{(n)} \leq \frac{\theta}{a}\right) - P_{\theta}\left(X_{(n)} \leq \frac{\theta}{b}\right) \\ &= \left(\frac{\theta/a}{\theta}\right)^n - \left(\frac{\theta/b}{\theta}\right)^n \\ P \text{ de cobertura} &= \left[\left(\frac{1}{a}\right)^n - \left(\frac{1}{b}\right)^n \right] \end{aligned}$$

Nota: En este caso, la probabilidad de cobertura NO depende de θ .

Solución Intervalo (2):

$$X_1, \dots, X_n \sim \text{Uniforme}(0, \theta)$$

Tomamos c, d fijos, con $0 \leq c \leq d$.


$$\begin{aligned} &P_{\theta}(X_{(n)} + c \leq \theta \leq X_{(n)} + d) \\ &= P_{\theta}(c \leq \theta - X_{(n)} \leq d) \\ &= P_{\theta}(c - \theta \leq -X_{(n)} \leq d - \theta) \\ &= P_{\theta}(\theta - c \geq X_{(n)} \geq \theta - d) \\ &= P_{\theta}(\theta - d \leq X_{(n)} \leq \theta - c) \\ &= F_{X_{(n)}}(\theta - c) - F_{X_{(n)}}(\theta - d) \\ &= \left(\frac{\theta - c}{\theta}\right)^n - \left(\frac{\theta - d}{\theta}\right)^n \\ &= \left(1 - \frac{c}{\theta}\right)^n - \left(1 - \frac{d}{\theta}\right)^n \end{aligned}$$

Probabilidad
de cobertura

Nota: Ahora, mi intervalo si depende de θ , algo que nos molesta.

Como vemos, a medida que θ crece, nuestra probabilidad de cobertura podría ser muy baja, por lo que no nos interesa realmente tomar este intervalo.

Cobertura del intervalo $[X_{(n)} + c, X_{(n)} + d]$:



Coeficiente de confianza

Para un estimador intervalar $[L(\mathbf{X}), U(\mathbf{X})]$ de un parámetro θ , se define su coeficiente de confianza como el ínfimo de las probabilidades de cobertura, es decir:

$$\inf_{\theta} P_{\theta}(\theta \in [L(\mathbf{X}), U(\mathbf{X})])$$

inf = Ínfimo = Mayor cota inferior.

Ejercicio:

En el problema anterior, encuentre el coeficiente de confianza de cada estimador propuesto.

Solución:

(1) $P_{\theta}(aX_{(n)} \leq \theta \leq bX_{(n)})$ no depende de θ , luego, es igual al coeficiente de confianza: $\left(\frac{1}{a}\right)^n - \left(\frac{1}{b}\right)^n$.

(2) $\inf_{\theta} \left\{ \left(1 - \frac{c}{\theta}\right)^n - \left(1 - \frac{d}{\theta}\right)^n \right\} = \lim_{\theta \rightarrow \infty} \left\{ \left(1 - \frac{c}{\theta}\right)^n - \left(1 - \frac{d}{\theta}\right)^n \right\} = 0$. Por lo tanto, no debiésemos utilizar este intervalo.

Conjunto de confianza

Para un parámetro cualquiera θ , se define un conjunto de confianza $1 - \alpha$ como un conjunto $C(\mathbf{X})$ tal que:

$$\inf_{\theta} P_{\theta}(\theta \in C(\mathbf{X})) = 1 - \alpha$$

Pivote para un parámetro

Una variable aleatoria $Q(\mathbf{X}, \theta)$ corresponde a un pivote para θ si, y sólo si su distribución NO depende de ningún parámetro desconocido. Es decir, la distribución $Q(\mathbf{X}, \theta)$ es la misma para todo θ .

Ejercicio:

Encuentre pivotes en las siguientes situaciones:

1. Familia de distribuciones de localización, con parámetro de localización θ .
2. Familia de distribuciones de escala, con parámetro de escala σ .
3. Familia de distribuciones de localización y escala, con parámetros θ y σ .

Solución:

1. Familia de distribuciones de localización, con parámetro de localización θ :

Sea f una densidad arbitraria que no depende de parámetros desconocidos.

Sea $\theta \in \mathbb{R}$ y se define $f_\theta(x) = f(x - \theta)$.

Ejemplo:

$$f(x) = N(0,1) = \frac{1}{(2\pi)^{1/2}} \cdot \exp\left\{-\frac{1}{2}x^2\right\}$$

$\theta \in \mathbb{R}$

$$f_\theta(x) = f(x - \theta) = \frac{1}{(2\pi)^{1/2}} \cdot \exp\left\{-\frac{1}{2}(x - \theta)^2\right\}$$

Recordamos

Al evaluarla en $1 - \theta$, ahora la distribución sí depende de θ , formando una familia:

$$\{f_\theta(x) = \text{Normal}(\theta, 1), \quad \theta \in \mathbb{R}\}$$

es familia de distribución de localización.

Lo que necesitamos:

$Q(\mathbf{X}, \theta)$ con distribución que no dependa de θ .

Entonces, ¿Cómo podemos, basándonos en \mathbf{x} y θ construir un Q que no dependa de θ ?

ACLARACIÓN: f_θ = Función que depende de θ . f = Función que NO depende de θ .

Sabemos que $x - \theta \sim \text{Normal}(0,1)$

$Q(\mathbf{X}, \theta)$ es pivote para θ , pues su distribución no depende de θ .

Entonces es pivote para la Normal(0,1).

Veamos ahora para el caso general:

$f(\cdot)$ No depende de θ

$$x \sim f_\theta(x) = f(x - \theta)$$

$$z = x - \theta$$

$$x = z + \theta$$

$$\left| \frac{dx}{dz} \right| = |1|$$

$$\begin{aligned} f_z(z) &= \left| \frac{dx}{dz} \right| f_\theta(x) \quad \leftarrow \text{“Teorema del Jacobiano”} \\ &= 1 \cdot f_\theta(z + \theta) \\ &= f((z + \theta) - \theta) \\ &= f(z) \text{ No depende de } \theta \end{aligned}$$

Entonces, si x está en familia de distribución de localización de parámetro $\theta \in \mathbb{R}$, $(x - \theta)$ será pivote para θ .

Hasta ahora, hemos trabajado con pivote para una sola observación. A continuación, veremos pivotes para conjunto de muestras:

$$x_1, \dots, x_n \sim f_\theta(x_i) = f(x_i - \theta)$$

Tenemos que la distribución de $X_i - \theta$ no depende de θ (Demostrado anteriormente).

Por lo tanto:

$$\sum(X_i - \theta) \text{ No depende de } \theta$$

Entonces, tampoco dependen de θ :

$$\begin{aligned} &= \sum X_i - n\theta \\ &= \bar{X} - \theta. \end{aligned}$$

$$\therefore \bar{X} - \theta = Q(\mathbf{X}, \theta) \text{ es pivote para } \theta.$$

Como Q no depende de θ , podemos decir que tiene una distribución F .

Siempre que tenemos un pivote, podemos escribir:

$$\begin{aligned}P(q_{\alpha/2} \leq Q(\mathbf{X}, \theta) \leq q_{1-\alpha/2}) &= 1 - \alpha \\P(q_{\alpha/2} \leq \bar{X} - \theta \leq q_{1-\alpha/2}) &= 1 - \alpha \\P\left(\underbrace{\bar{X} + q_{1-\alpha/2}}_{L(\mathbf{X})} \leq \theta \leq \underbrace{\bar{X} + q_{\alpha/2}}_{U(\mathbf{X})}\right) &= 1 - \alpha\end{aligned}$$

Entonces, nuestra probabilidad de cobertura es igual a $1 - \alpha$ y NO depende de θ , por lo que el coeficiente de confianza también es $1 - \alpha$.

Si:

$$\begin{aligned}L(\mathbf{X}) &= \bar{X} + q_{1-\alpha/2} \\U(\mathbf{X}) &= \bar{X} + q_{\alpha/2}\end{aligned}$$

Entonces:

$$P(L(\mathbf{X}) \leq \theta \leq U(\mathbf{X})) = 1 - \alpha$$

Y, $[L(\mathbf{X}), U(\mathbf{X})]$ es intervalo con probabilidad de cobertura $(1 - \alpha)$ para θ . Dado que no depende de θ , también es intervalo de confianza, pues:

$$\inf_{\theta} P(L(\mathbf{X}) \leq \theta \leq U(\mathbf{X})) = 1 - \alpha$$

2. Familia de distribuciones de escala, con parámetro de escala σ :

Al igual que en una familia de localización, existe una función distribución f que no depende de ningún parámetro desconocido.

Tomamos $\sigma > 0$.

Entonces, ahora definimos una función de probabilidad que dependa de σ , pero, que va a estar basado en esta distribución f .

$$\left\{f_{\sigma}(x) = \frac{1}{\sigma} f\left(\frac{x}{\sigma}\right), \quad \sigma > 0\right\}$$

Familia de distribuciones de escala.

Ejemplo:

$$f(x) = \frac{1}{\sqrt{2\pi}} \cdot \exp\left\{-\frac{1}{2}x^2\right\}$$

$$f_{\sigma}(x) = \frac{1}{\sigma} f\left(\frac{x}{\sigma}\right) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot \exp\left\{-\frac{1}{2\sigma^2}x^2\right\}$$

Entonces, la familia

$$\{Normal(0, \sigma^2), \sigma > 0\}$$

Es una familia de escala.

Ahora, proponemos:

$$\frac{x}{\sigma} = u \Rightarrow x = u \cdot \sigma \Rightarrow \left| \frac{dx}{du} \right| = \sigma$$

Teorema de cambio de variable:

$$\begin{aligned} f_U(u) &= \sigma \cdot f_\sigma(x) \\ &= \sigma \cdot \frac{1}{\sigma} \cdot f\left(\frac{x}{\sigma}\right) \\ &= f\left(\frac{u \cdot \sigma}{\sigma}\right) \\ &= f(u) \end{aligned}$$

$$\boxed{U = \frac{x}{\sigma}} = Q(X, \sigma) \sim f \longrightarrow \text{No depende de ningún parámetro desconocido.}$$

Luego, x/σ es pivote para σ .

Si tenemos:

$$X_1, \dots, X_n \sim f_\sigma$$

$$\Rightarrow \boxed{\frac{X_i}{\sigma} \text{ pivote para } i = 1, \dots, n}$$

Usualmente se toma:

$$\frac{\sum x_i^2}{\sigma^2}$$

$$P\left(q_{\alpha/2} < \frac{\sum x_i^2}{\sigma^2} < q_{1-\alpha/2}\right) = 1 - \alpha$$

$$P\left(\underbrace{\frac{\sum x_i^2}{q_{1-\alpha/2}}}_{L(X)} < \sigma^2 < \underbrace{\frac{\sum x_i^2}{q_{\alpha/2}}}_{U(X)}\right) = 1 - \alpha$$

Sea el intervalo aleatorio $[L(X), U(X)]$. Su probabilidad de cobertura:

$$P(L(X) < \sigma^2 < U(X)) = 1 - \alpha$$

Coefficiente de confianza

$$\inf_{\sigma > 0} P(L(\mathbf{X}) < \sigma^2 < U(\mathbf{X}))$$

$$\inf_{\sigma > 0} (1 - \alpha) = 1 - \alpha$$

Ejercicio:

Encuentre un pivote para θ en la distribución Exponencial de media $1/\theta$.

Solución:

$$X_1, \dots, X_n \sim \text{Exp}(\theta)$$

Primero mostramos que sea familia de escala:

$$f(x) = e^{-x}, \quad x > 0$$

$$\{f_\sigma(x) = \frac{1}{\sigma} e^{-x/\sigma}, \quad \sigma > 0\}$$

\therefore Exponencial($1/\sigma$) es familia de escala.

Tenemos que: $\frac{x_i}{\sigma}$ es pivote para σ .

Tomamos:

$$\frac{\sum x_i}{\sigma} \text{ pivote para } \sigma$$

Luego,

$$\underbrace{\sum x_i}_U \sim \text{Gamma}\left(n, \frac{1}{\sigma}\right)$$

$$V = \frac{U}{\sigma} \Rightarrow u = \sigma \cdot v \Rightarrow \left| \frac{du}{dv} \right| = \sigma$$

$$f_\sigma(u) = \left(\frac{1}{\sigma}\right)^n \frac{u^{n-1} \cdot e^{-u/\sigma}}{\Gamma(n)}, \quad u > 0$$

$$f_V(v) = \frac{\sigma \cdot \sigma^{-n} (\sigma v)^{n-1} \cdot e^{-v}}{\Gamma(n)}, \quad v > 0$$

$$= \frac{1}{\Gamma(n)} \cdot v^{n-1} \cdot e^{-v}, \quad v > 0$$

$$V = \frac{\sum x_i}{\sigma} \sim \text{Gamma}(n, 1)$$

$$P\left(q_{\alpha/2} < \frac{\sum x_i}{\sigma} < q_{1-\alpha/2}\right) = 1 - \alpha$$

$$P\left(\frac{\sum x_i}{\underbrace{q_{1-\alpha/2}}_{L(X)}} < \sigma < \frac{\sum x_i}{\underbrace{q_{\alpha/2}}_{U(X)}}\right) = 1 - \alpha$$

$$q_{1-\alpha/2} = q_{\text{Gamma}(1 - \alpha/2, n, 1)}$$

$$q_{\alpha/2} = q_{\text{Gamma}(\alpha/2, n, 1)}$$

Usando $\sigma = 1/\theta$ es posible obtener un intervalo de confianza $(1 - \alpha)$ para θ .

Caso general:

Considere un estadístico $T(\mathbf{X})$ con función de densidad f_θ . En general, se busca factorizar su densidad en la forma:

$$f_\theta(t) = g(Q(t, \theta)) \left| \frac{\partial Q(t, \theta)}{\partial t} \right|,$$

con Q función monótona en t , para cada valor de θ .

Para encontrar un intervalo de $(1 - \alpha)100\%$ de confianza, es posible plantear la igualdad.

$$P_\theta(a \leq Q(t, \theta) \leq b) \geq 1 - \alpha$$

Teorema:

Sea $T(\mathbf{X})$ una variable aleatoria **continua** con función de distribución F_θ .
Sea $0 < \alpha < 1$ un valor constante. Para todo $t \in T$, se definen $\theta_L(t)$ y $\theta_U(t)$ tales que:

1. Si F_θ es decreciente en θ para cada t .

$$F_{\theta_U(t)}(t) = \frac{\alpha}{2} \qquad F_{\theta_L(t)}(t) = 1 - \frac{\alpha}{2}$$

2. Si F_θ es creciente en θ para cada t .

$$F_{\theta_U(t)}(t) = 1 - \frac{\alpha}{2} \qquad F_{\theta_L(t)}(t) = \frac{\alpha}{2}$$

Entonces $[\theta_{L(t)}, \theta_{U(t)}]$ corresponde a un intervalo de confianza $(1 - \alpha)100\%$ para θ .

Teorema:

Sea $T(\mathbf{X})$ una variable aleatoria **discreta** con función de distribución F_θ .
Sea $0 < \alpha < 1$ un valor constante. Para todo $t \in T$, se definen $\theta_L(t)$ y $\theta_U(t)$ tales que:

1. Si F_θ es decreciente en θ para cada t .

$$P_{\theta_{U(t)}}(T \leq t) = \frac{\alpha}{2} \qquad P_{\theta_{L(t)}}(T \geq t) = 1 - \frac{\alpha}{2}$$

2. Si F_θ es creciente en θ para cada t .

$$P_{\theta_{U(t)}}(T \geq t) = 1 - \frac{\alpha}{2} \qquad P_{\theta_{L(t)}}(T \leq t) = \frac{\alpha}{2}$$

Entonces $[\theta_{L(t)}, \theta_{U(t)}]$ corresponde a un intervalo de confianza $(1 - \alpha)100\%$ para θ .

Propuestos:

1. $X_1, \dots, X_n \sim \text{Normal}(\theta, \sigma^2)$ con σ^2 desconocido. Encontrar un intervalo de confianza $(1 - \alpha)$ para θ considerando que corresponde a una familia de localización.
2. $X_1, \dots, X_n \sim \text{Normal}(\theta, \sigma^2)$ con σ^2 desconocido. Encontrar un intervalo de confianza $(1 - \alpha)$ para θ .
3. En los casos anteriores, encuentre intervalos de confianza $(1 - \alpha)$ de la forma $(-\infty, U(X)]$ y $[L(X), +\infty)$.

Modelo de Regresión Lineal simple:

El modelo de regresión lineal simple para explicar el comportamiento de una variable respuesta, Y , en términos de un predictor x , para n pares de observaciones de la forma $(x_i, Y_i), i = 1, \dots, n$ corresponde a:

$$Y_i \sim \text{Normal}(\beta_0 + \beta_1 x_i, \sigma^2)$$

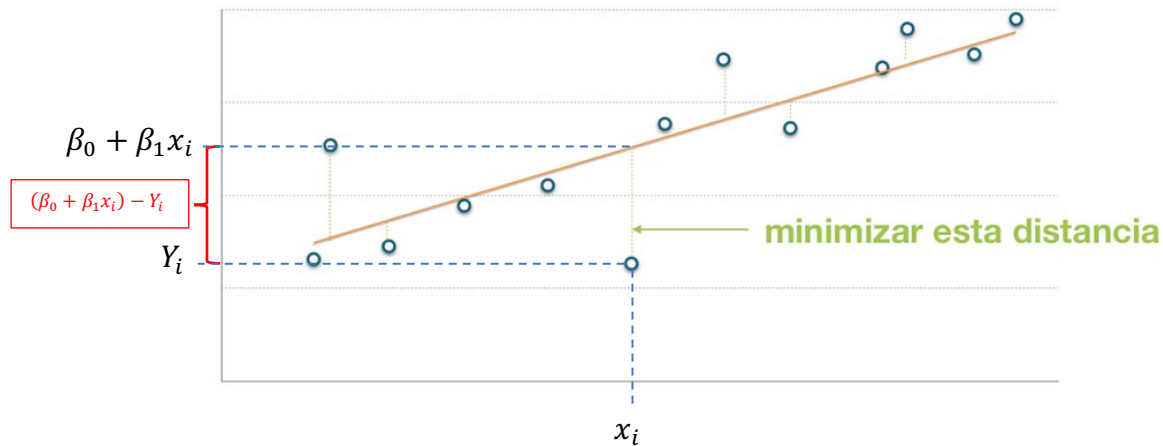
con Y_1, \dots, Y_n independientes.

Formulación alternativa:

El modelo puede ser reescrito como:

$$Y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$

$$\epsilon_i \sim \text{Normal}(0, \sigma^2), \quad i = 1, \dots, n$$



Estimadores de Mínimos Cuadrados Ordinarios de β_0 y β_1 :

Como me interesan todas las distancias, buscaremos minimizar la sumatoria de éstas.

$$\begin{aligned} S(\beta_0, \beta_1) &= \sum_{i=1}^n \epsilon_i^2 \\ &= \sum_{i=1}^n (Y_i - (\beta_0 + \beta_1 x_i))^2 \end{aligned}$$

Notar que elevamos al cuadrado para eliminar los signos negativos, solo nos interesa la distancia.

Para resolver esto, derivamos con respecto a β_0 y β_1 e igualamos a 0:

$$\left. \begin{aligned} \frac{\partial S}{\partial \beta_0} &= -2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i) = 0 \\ \frac{\partial S}{\partial \beta_1} &= -2 \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 x_i) x_i = 0 \end{aligned} \right\} \text{Punto crítico}$$

Luego, se calcula la matriz Hessiana y mostramos que sea definida positiva (porque estamos minimizando) en el punto crítico.

Resolviendo este problema de minimización de manera analítica, se obtienen las expresiones para los valores buscados:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}} \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{x}$$

Observaciones:

- 1) Alrededor de 1920, Fischer propuso la estimación máxima versímil. También, se da cuenta que los parámetros *MV* son:

$$\begin{aligned}\hat{\beta}_0^{MV} &= \hat{\beta}_0 \\ \hat{\beta}_1^{MV} &= \hat{\beta}_1\end{aligned}$$

$$\sigma_{MV}^2 = \frac{\sum_{i=1}^n (Y_i - (\beta_0 + \beta_1 x_i))^2}{n}$$

- 2) Pero σ_{MV}^2 no es insesgado, entonces se toma uno corregido:

$$\hat{\sigma}^2 = \sigma_M^2 \cdot \frac{n}{n-2}$$

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (Y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i))^2}{n-2}$$

El $n - 2$ viene de que estamos estimando 2 parámetros, β_0 y β_1 .

Este último, viene siendo el estimador de σ^2 de mínimos cuadrados, es decir:

$$E(\hat{\sigma}^2) = \sigma^2$$

Ahora, si en mi gráfico todos los Y_i parecen estar dentro del mismo rango, es decir que para cualquier valor de x_i el valor de Y_i siempre estará en el mismo rango, podemos pensar que Y_i no depende de x_i . En este caso, el valor de β_1 debe ser igual a 0. Sin embargo, por ruido, podemos obtener valores de β_1 cercanos a 0, pero no el 0 mismo, lo que podría ser un error al interpretar el gráfico.

Es por esto que nos preguntamos,

$$¿\beta_1 \neq 0?$$

Para resolver esto, lo ideal es usar un test de hipótesis, pero con las herramientas que tenemos nosotros vamos a hacer un intervalo de confianza. Aquí, revisaremos a si el 0 está en el intervalo, o no. Si 0 está en el intervalo, no podríamos descartar que el valor de β_1 sea igual a 0. Por otro lado, si el intervalo no contiene al 0, entonces concluimos que β_1 es distinto de 0, y existiría una regresión.

La estrategia que tenemos, es la estrategia del pivote. Entonces necesitamos un pivote para β_1 . ¿Qué era un pivote? Revisar página 25.

$$Q(\mathbf{Y}, \beta_1) \sim F \text{ no depende de parámetros desconocidos}$$

Como $\hat{\beta}_1 = S_{xy}/S_{xx}$:

Se puede demostrar (raramente) que:

$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(Y_i - \bar{Y}) = \sum_{i=1}^n (x_i - \bar{x})Y_i$$

Luego,

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})Y_i}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_1 = \sum_{i=1}^n \underbrace{\left(\frac{x_i - \bar{x}}{S_{xx}} \right)}_{cte} \cdot Y_i = \sum_{i=1}^n d_i \cdot Y_i \Rightarrow \text{Combinación lineal de Normales}$$

$$\hat{\beta}_1 \sim \text{Normal}$$

$$E(\hat{\beta}_1) = E\left(\sum_{i=1}^n d_i \cdot Y_i\right) = \sum_{i=1}^n E(d_i \cdot Y_i) = \sum_{i=1}^n d_i \cdot E(Y_i)$$

$$= \sum_{i=1}^n d_i \cdot (\beta_0 + \beta_1 x_i) = \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{S_{xx}} \right) \cdot (\beta_0 + \beta_1 x_i)$$

$$= \beta_0 \frac{\sum_{i=1}^n \overbrace{(x_i - \bar{x})}^0}{S_{xx}} + \beta_1 \frac{\sum_{i=1}^n \overbrace{(x_i - \bar{x})x_i}^{S_{xx}}}{S_{xx}}$$

$$= \boxed{\beta_1} \Rightarrow \text{Es insesgado}$$

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n (x_i - \bar{x})x_i$$

$$\text{Var}(\hat{\beta}_1) = \text{Var}\left(\sum_{i=1}^n d_i \cdot Y_i\right) = \dots = \frac{\sigma^2}{S_{xx}}$$

$$\hat{\beta}_1 \sim \text{Normal}\left(\beta_1, \frac{\sigma^2}{S_{xx}}\right)$$

Tratamos de hacer el pivote estandarizando:

$$\frac{\hat{\beta}_1 - \beta_1}{\sigma/\sqrt{S_{xx}}} \sim \text{Normal}(0,1)$$

$$(\hat{\beta}_1 - \beta_1)\sqrt{S_{xx}} \sim \text{Normal}(0, \sigma^2)$$

¿Es esto igual al pivote $Q(\hat{\beta}_1, \beta_1)$ que buscamos?

NO, no es igual al pivote, ya que depende de σ , el cual es un parámetro desconocido.

¿Qué podemos hacer para solucionarlo?

$$\boxed{\frac{\hat{\beta}_1 - \beta_1}{\hat{\sigma}/\sqrt{S_{xx}}} \sim t_{n-2}}$$

Este pivote, si cumple.

$$P(t_{n-2}^{\alpha/2} < Q(\mathbf{Y}, \beta_1) < t_{n-2}^{1-\alpha/2}) = 1 - \alpha$$

Por simetría se t_n :

$$P\left(-t_{n-2}^{1-\alpha/2} < \frac{\hat{\beta}_1 - \beta_1}{\hat{\sigma}/\sqrt{S_{xx}}} < t_{n-2}^{1-\alpha/2}\right) = 1 - \alpha$$

$$\hat{\beta}_1 - \frac{t_{n-2}^{1-\alpha/2} \hat{\sigma}}{\sqrt{S_{xx}}} < \beta_1 < \hat{\beta}_1 + \frac{t_{n-2}^{1-\alpha/2} \hat{\sigma}}{\sqrt{S_{xx}}}$$

Con 95% de confianza, β_1 está entre $-0,55$ y $-0,26$. Dado que no contiene el valor de $\beta_1 = 0$, concluimos que el pH aporta para explicar el comportamiento de la concentración de Hg en el tejido de los peces.

- Se estima que la media del contenido de Hg en los peces de un lago cuyo pH es 1 unidad mayor que otro es 0.40 unidades menor (ppm, escala log).
- Se estima que, para un lago con un pH de 6, el contenido medio de Hg (log) corresponde a:

$$\hat{\beta}_0 + \hat{\beta}_1 \cdot 6 = -0,67,$$

es decir, a:

$$\exp\{-0,67\} = 0,51 \text{ ppm}$$

Pivotes

Funciones en donde su distribución no depende del parámetro.

Ejemplo común:

Sea $X_1, \dots, X_n \sim N(\mu, \sigma^2)$:

$$Q_1(\mathbf{X}, \mu) = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0,1) \quad \sigma \text{ conocido}$$

$$Q_2(\mathbf{X}, \mu) = \frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t_{n-1} \quad \sigma \text{ desconocido}$$

$$Q_3(\mathbf{X}, \sigma^2) = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$