

## Interrogación 2

¿Cómo evaluamos un autómata no-determinista?

**NFA on-the-fly:**

Para un autómata no-determinista  $\mathcal{A} = (Q, \Sigma, \Delta, I, F)$ :

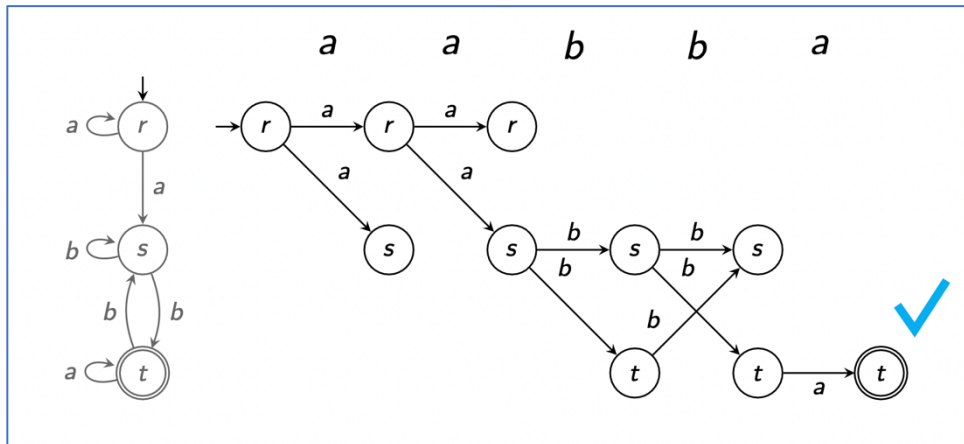
- $2^Q = \{S \mid S \subseteq Q\}$  es el conjunto potencia de  $Q$ .
- $q_0^{det} = I$ .
- $\delta^{det}: 2^Q \times \Sigma \rightarrow 2^Q$  tal que:

$$\delta^{det}(S, a) = \{q \in Q \mid \exists p \in S. (p, a, q) \in \Delta\}$$

- $F^{det} = \{S \in 2^Q \mid S \cap F \neq \emptyset\}$ .

Estrategia:

- Mantenemos un conjunto  $S$  de estados actuales.
- Por cada nueva letra  $a$ , calculamos el conjunto  $\delta^{det}(S, a)$ .



**Function** eval-NFAonthe-fly ( $\mathcal{A}, w$ )

```

S := I
for i = 1 to n do
    Sold := S
    S := ∅
    foreach p ∈ Sold do
        S := S ∪ {q | (p, ai, q) ∈ Δ}
return check (S ∩ F ≠ ∅)
    
```

Complejidad:  $\mathcal{O}(|\mathcal{A}| \cdot |w|)$

**$\epsilon$ -NFA on-the-fly:**

**Function** eval-eNFAonthe-fly ( $\mathcal{A}, w$ )

$S := \epsilon\text{-closure}(\Delta, I)$

**for**  $i = 1$  **to**  $n$  **do**

$S_{\text{old}} := S$

$S := \emptyset$

**foreach**  $p \in S_{\text{old}}$  **do**

$S := S \cup \{q \mid (p, a_i, q) \in \Delta\}$

$S := \epsilon\text{-closure}(\Delta, S)$

**return** **check** ( $S \cap F \neq \emptyset$ )

Complejidad:  $\mathcal{O}(|\mathcal{A}| \cdot |w|)$

## Transductores

Un transductor (en inglés, transducer) es una tupla:

$$\mathcal{T} = (Q, \Sigma, \Omega, \Delta, I, F)$$

- $Q$  es un conjunto finito de estados.
- $\Sigma$  es el alfabeto del input.
- $\Omega$  es el alfabeto del **output**.
- $\Delta \subseteq Q \times (\Sigma \cup \{\epsilon\}) \times (\Omega \cup \{\epsilon\}) \times Q$  es la relación de transición.
- $I \subseteq Q$  es el conjunto de estados iniciales.
- $F \subseteq Q$  es el conjunto de estados finales.

*“Intuitivamente, una configuración  $(q, au, vb)$  representa que  $\mathcal{T}$  se encuentra en el estado  $q$ , procesando la palabra  $au$  y leyendo  $a$ , y hasta ahora grabó la palabra  $vb$  y el último símbolo impreso es  $b$ .”*

### Definición

Se define la relación  $\vdash_{\mathcal{T}}$  de **siguiente-paso** entre configuraciones de  $\mathcal{T}$ :

$$(p_1, u_1, v_1) \vdash_{\mathcal{T}} (q, u_2, v_2)$$

Si, y sólo si, existe  $(p, a, b, q) \in \Delta$  tal que  $u_1 = a \cdot u_2$  y  $v_2 = v_1 \cdot b$

## Definiciones

- $\mathcal{T}$  **entrega**  $v$  con **input**  $u$  si existe una configuración **inicial**  $(q_0, u, \epsilon)$  y una configuración **final**  $(q_f, \epsilon, v)$  tal que:

$$(q_0, u, \epsilon) \vdash_{\mathcal{T}}^* (q_f, \epsilon, v)$$

- Se define la función  $\llbracket \mathcal{T} \rrbracket: \Sigma^* \rightarrow 2^{\Omega^*}$ :

$\llbracket \mathcal{T} \rrbracket \rightarrow \text{Semántica}$

$$\llbracket \mathcal{T} \rrbracket(u) = \{v \in \Omega^* \mid \mathcal{T} \text{ entrega } v \text{ con input } u\}$$

- Se dice que  $f: \Sigma^* \rightarrow 2^{\Omega^*}$  es una **función racional** si existe un transductor  $\mathcal{T}$  tal que  $f = \llbracket \mathcal{T} \rrbracket$ .


Un transductor define una función de palabras a conjunto de palabras.

## Definiciones

Para una relación  $R \subseteq \Sigma^* \times \Omega^*$  se define:

- $\pi_1(R) = \{u \in \Sigma^* \mid \exists v \in \Omega^*. (u, v) \in R\} \Rightarrow$  "Dominio" de  $R$ .
- $\pi_2(R) = \{v \in \Omega^* \mid \exists u \in \Sigma^*. (u, v) \in R\} \Rightarrow$  "Recorrido" de  $R$ .

¿Cuál es el lenguaje definido por  $\pi_1(\llbracket \mathcal{T} \rrbracket)$  y  $\pi_2(\llbracket \mathcal{T} \rrbracket)$ ?



Dominio: Todas las palabras con 2 o más  $a$ 's

Recorrido:  $c^*$

## Teorema

Sea  $\mathcal{T}_1$  y  $\mathcal{T}_2$  dos transductores con  $\Sigma$  y  $\Omega$  alfabetos de input y output.

Las siguientes son **relaciones racionales**.

1.  $\llbracket \mathcal{T}_1 \rrbracket \cup \llbracket \mathcal{T}_2 \rrbracket = \{(u, v) \in \Sigma^* \times \Omega^* \mid (u, v) \in \llbracket \mathcal{T}_1 \rrbracket \vee (u, v) \in \llbracket \mathcal{T}_2 \rrbracket\}$ .
2.  $\llbracket \mathcal{T}_1 \rrbracket \cdot \llbracket \mathcal{T}_2 \rrbracket = \{(u_1 u_2, v_1 v_2) \in \Sigma^* \times \Omega^* \mid (u_1, v_1) \in \llbracket \mathcal{T}_1 \rrbracket \wedge (u_2, v_2) \in \llbracket \mathcal{T}_2 \rrbracket\}$
3.  $\llbracket \mathcal{T}_1 \rrbracket^* = \bigcup_{k=0}^{\infty} \llbracket \mathcal{T}_1 \rrbracket^k$

## Teorema


Existen transductores  $\mathcal{T}_1$  y  $\mathcal{T}_2$  sobre  $\Sigma$  y  $\Omega$  tal que:

$$\llbracket \mathcal{T}_1 \rrbracket \cap \llbracket \mathcal{T}_2 \rrbracket = \{(u, v) \in \Sigma^* \times \Omega^* \mid (u, v) \in \llbracket \mathcal{T}_1 \rrbracket \wedge (u, v) \in \llbracket \mathcal{T}_2 \rrbracket\}$$

**NO** es una relación racional.

## Demostración

Considere los siguientes transductores:



$$\llbracket \mathcal{T}_1 \rrbracket = \{(a^n, b^n c^m) \mid n \geq 0, m \geq 0\}.$$

$$\llbracket \mathcal{T}_2 \rrbracket = \{(a^n, b^m c^n) \mid n \geq 0, m \geq 0\}$$

Pero  $\llbracket \mathcal{T}_1 \rrbracket \cap \llbracket \mathcal{T}_2 \rrbracket = \{(a^n, b^n c^n) \mid n \geq 0\}$ , y, por lo tanto,  $\llbracket \mathcal{T}_1 \rrbracket \cap \llbracket \mathcal{T}_2 \rrbracket$  no es racional. (El recorrido de la intersección es  $\{b^n \cdot c^n\}$  el cual no es racional).

## Definición

Decimos que un transductor  $\mathcal{T}$  define una función (parcial) si:

$$\text{para todo } u \in \Sigma^* \text{ se tiene que } |\llbracket \mathcal{T} \rrbracket(u)| \leq 1.$$

## Definición

Decimos que  $\mathcal{T} = (Q, \Sigma, \Omega, \Delta, I, F)$  es **determinista** si cumple que:

1.  $\mathcal{T}$  define una función  $\llbracket \mathcal{T} \rrbracket: \Sigma^* \rightarrow \Omega^*$ .
2. Para todo  $(p, a_1, b_1, q_1) \in \Delta$  y  $(p, a_2, b_2, q_2) \in \Delta$ , si  $a_1 = a_2$ , entonces  $b_1 = b_2$  y  $q_1 = q_2$ , es decir, son la misma transición.
3. Si  $(p, \epsilon, b, q) \in \Delta$ , entonces para todo  $(p, a', b', q') \in \Delta$ , se tiene que  $(a', b', q') = (\epsilon, b, q)$ . Es decir, si tengo alguna  $\epsilon$  transición, esta debe ser la única transición que sale de ese estado.

## Sintaxis y semántica de un lenguaje de programación

### Definición

1. La **sintaxis** de un lenguaje es un conjunto de reglas que describen los programas válidos que tienen significado.
2. La **semántica** de un lenguaje define el significado de un programa correcto según la sintaxis.

### Verificación de sintaxis

En este proceso se busca:

- Verificar la sintaxis de un programa.
- Entregar la estructura de un programa (árbol de parsing).

Consta de 3 etapas:

1. Análisis léxico (**Lexer**).
2. Análisis sintáctico (**Parser**).
3. Análisis semántico.

### Análisis léxico (LEXER)

- El análisis léxico consta en dividir el programa en una secuencia de **tokens**.
- Un **token** (o lexema) es un substring (válido) dentro de un programa.
- Un **token** está compuesto por:
  - Tipo
  - Valor (el valor mismo del substring).

Tipos usuales de **tokens** en lenguajes de programación:


- **number** (constante): 2, 235, 495, ...
- **string** (constante): "hello", "ilove TDA", ...
- **keywords**: if, for, ...
- **identificadores**: pos, init, rate, ...
- **delimitadores**: "{", "}", "(", ")", ",", ...
- **operadores**: "=", "+", "<", "<=", ...

```
pos = init + rate * 60
```

Tipo	Valor
id	pos
EQ	=
id	init
PLUS	+
id	rate
MULT	*
number	60

## Generador de análisis léxico (Lex)

- Un generador de análisis léxico es un software que, a través de un programa fuente, crea el código necesario para hacer el análisis léxico.
- Lex es el analizador léxico estándar en Unix en el lenguaje C.



El formato de un programa en Lex es de la forma:

```
declaraciones
%%
reglas de traducción
%%
funciones auxiliares
```

### Ejemplo declaraciones:

```
%{
#include "misconstantes.h" /* def de IF, ELSE, ID, NUMBER */
%}
delim  [\t\n]
ws     {delim}+
%%
...
```

### Ejemplo funciones auxiliares:

...

%%

```
void printID(){printf("Id: %s\n", yytext);}
```

```
void printNumebr(){printf("Number: %s\n", yytext);}
```

Las **reglas de traducción** tienen la siguiente forma:

Patrón { Acción }

- **Patrón** está definido por una **expresión regular**.
- **Acción** es código C embebido.

### Ejemplo: reglas de traducción:

```
[ \t\n]+          { \* sin accion *\}  
if               { return(IF);}  
else            { return(ELSE);}  
[A-Za-z]([A-Za-z0-9])* {printID(); return(ID);}  
[0-9]+          {printNumber(); return(NUMBER);}
```

### **Resolución de conflictos en Lex**

Si **varios prefijos** del input satisfacen uno o más patrones:

1. Se prefiere el **prefijo más largo** por sobre el prefijo más corto.
2. Si el prefijo más corto satisface uno o más patrones, se prefiere **el patrón listado primero** en el programa lex.1.

### **¿Cómo evaluamos los patrones en lex.1?**

Sea  $P_1, \dots, P_k$  los patrones y  $C_1, \dots, C_k$  las acciones en el programa "lex.1", respectivamente.

#### **Primer paso**

Para cada patrón  $P_i$  construimos un NFA  $\mathcal{A}_i = (Q_i, \Sigma, \Delta_i, \{q_0^i\}, \{q_f^i\})$  con un solo estado inicial  $q_0^i$  y un solo estado final  $q_f^i$ .

Supondremos las siguientes **simplificaciones**:

1. Cada lexema esta separado por un símbolo de espacio "\_".
2. Documento termina con un símbolo especial EOF.
3. No hay conflictos entre patrones.

Ejemplo conflictos:

```
if                                { return(IF);}
else                             { return(ELSE);}
[A-Za-z]([A-Za-z0-9])* {printID(); return(ID);}
```

**¿Cómo evaluamos los patrones en paralelo?**

- $\mathcal{A}_i = (Q_i, \Sigma, \Delta_i, \{q_0^i\}, \{q_f^i\})$  el NFA para el **patrón**  $P_i$  y
- $C_i$  la **acción** de  $P_i$  con  $i \leq k$ .

Evaluamos el transductor determinista:

$$\mathcal{T} = (Q, \Sigma, \{C_i\}_{i \leq k}, \Delta, \{q_0\}, F)$$

- $Q = 2^{\{\cup_{i=1}^k Q_i\}}$
- $q_0 = \{q_0^1, q_0^2, \dots, q_0^k\}$
- $(S, a, \epsilon, S') \in \Delta$  si, y solo si,  $S' = \{q \mid \exists i. \exists p \in S. (p, a, q) \in \Delta_i\}$
- $(S, \_, C_i, q_0), (S, EOF, C_i, q_0) \in \Delta$  si, y solo si,  $q_f^i \in S$ .
- $F = \{q_0\}$

**Lexer on-the-fly (simplificado)**

Sea  $\mathcal{A}_i = (Q_i, \Sigma, \Delta_i, \{q_0^i\}, \{q_f^i\})$  el NFA para el patrón  $P_i$  y  $w = a_1 \dots a_n$ .

```
Function lexer-onthefly ( $\mathcal{A}_1, \dots, \mathcal{A}_k, w$ )
   $S := \{q_0^1, q_0^2, \dots, q_0^k\}$ 
  for  $j = 1$  to  $n$  do
    if  $a_j \neq \_$  and  $a_j \neq EOF$  then
       $S_{old} := S$ 
       $S := \emptyset$ 
      foreach  $i = 1$  to  $k$  do
        foreach  $p \in S_{old} \cap Q_i$  do
           $S := S \cup \{q \mid (p, a_j, q) \in \Delta_i\}$ 
    ...
```

```
Function lexer-onthefly ( $\mathcal{A}_1, \dots, \mathcal{A}_k, w$ )
   $S := \{q_0^1, q_0^2, \dots, q_0^k\}$ 
  for  $j = 1$  to  $n$  do
    ...
    else if  $a_j = \_$  or  $a_j = EOF$  then
      if  $q_f^1 \in S$  then
        execute  $C_1$ 
      ...
      else if  $q_f^k \in S$  then
        execute  $C_k$ 
      else
        ERROR
       $S := \{q_0^1, q_0^2, \dots, q_0^k\}$ 
  return
```



## Tiempo análisis léxico

Si  $|P_i|$  es el tamaño del patrón  $P_i$ :

$$\mathcal{O}((|P_1| + \dots + |P_k|) \cdot |w|)$$

## Algunas conclusiones/observaciones

1. El análisis léxico es equivalente a evaluar un **transductor** que simula los patrones en **paralelo**.
2. El análisis léxico también maneja **conflictos entre reglas** y otros detalles.

## Algoritmo de Knuth-Morris-Prat


### Problema

Dado un patrón  $w = w_1 \dots w_m$  y un documento  $d = d_1 \dots d_n$ , encontrar todas las posiciones donde aparece  $w$  en  $d$ , o sea, enumerar:


$$\{(i, j) \mid w = d_i d_{i+1} \dots d_j\}$$

### Autómata de un patrón

Ejemplo: palabra  $w = nano$



### Autómata determinizado:



Sea  $w = w_1 \dots w_m$  y  $\mathcal{A}_w^{det} = (Q^{det}, \Sigma, \delta^{det}, \{0\}, F^{det})$  la determinización de  $\mathcal{A}_w$ .

### Teorema

Para todo  $S \in Q^{det}$  y  $i \in \{0, 1, \dots, m\}$  se cumple que:

$$i \in S \text{ si, y solo si, } w_1 \dots w_i \text{ es un sufijo de } w_1 \dots w_{\max(S)}.$$

### Corolarios

- Para todo  $S_1, S_2 \in Q^{det}$ , si  $\max(S_1) = \max(S_2)$  entonces  $S_1 = S_2$ .
- $\mathcal{A}_w^{det}$  tiene  $|w| + 1$  estados y a lo más  $\mathcal{O}(|w|^2)$  transiciones.

Por lo tanto, encontrar todos los substrings de  $w$  en  $d$  toma tiempo  $\mathcal{O}(|d| + |w|^2)$

### Demostración Teorema

Sea  $S \in Q^{det}$  un conjunto de estados cualquiera alcanzable desde  $\{0\}$ .

Entonces existe una palabra  $u = a_1 \dots a_k$  tal que  $\hat{\delta}^{det}(\{0\}, u) = S$ .

Por la demostración que  $\mathcal{L}(\mathcal{A}^{det}) = \mathcal{L}(\mathcal{A})$  para todo NFA  $\mathcal{A}$ , sabemos que  $j \in S$  si, y solo si, existe una ejecución de  $\mathcal{A}_w$  sobre  $u$ :

$$0 = q_0 \xrightarrow{a_1} q_1 \xrightarrow{a_2} \dots \xrightarrow{a_k} q_k = j$$

Por la definición de  $\mathcal{A}_w$  esta ejecución es de la forma:

$$0 \xrightarrow{a_1} 0 \xrightarrow{a_2} \dots \xrightarrow{a_{k-j}} 0 \underbrace{\xrightarrow{a_{k-j+1}} 1 \xrightarrow{a_{k-j+2}} 2 \xrightarrow{a_{k-j+3}} \dots \xrightarrow{a_k} j}_{w_1 \dots w_j}$$

Por lo tanto,  $w_1 w_2 \dots w_j$  es sufijo de  $a_1 \dots a_k$ .

### Propiedad

Para toda  $u = a_1 \dots a_k$  tal que  $\hat{\delta}^{det}(\{0\}, u) = S$ , y para todo  $j \leq m$ :

$$j \in S \text{ si, y solo si, } w_1 \dots w_j \text{ es sufijo de } a_1 \dots a_k$$

### Demostración del teorema ( $\Rightarrow$ )

Como  $S$  es alcanzable desde  $\{0\}$ ,  
entonces existe  $u = a_1 \dots a_k$  tal que  $\hat{\delta}^{det}(\{0\}, u) = S$ .

Como  $\max(S) \in S$ , entonces  $w_1 \dots w_{\max(S)}$  es sufijo de  $a_1 \dots a_k$ .

Suponga que  $i \in S$ . Entonces  $w_1 \dots w_i$  es sufijo de  $a_1 \dots a_k$ .

Como  $i \leq \max(S)$  entonces:

$$a_1 a_2 \dots a_{k-\max(S)} \overbrace{a_{k-\max(S)+1} \dots a_{k-i} a_{k-i+1} \dots a_k}^{w_1 \dots w_{\max(S)}} \underbrace{a_{k-i+1} \dots a_k}_{w_1 \dots w_i}$$

Por lo tanto,  $w_1 \dots w_i$  es sufijo de  $w_1 \dots w_{\max(S)}$ .

### Demostración del teorema ( $\Leftarrow$ )

Como  $S$  es alcanzable desde  $\{0\}$ ,  
entonces existe  $u = a_1 \dots a_k$  tal que  $\hat{\delta}^{det}(\{0\}, u) = S$ .

Como  $\max(S) \in S$ , entonces  $w_1 \dots w_{\max(S)}$  es sufijo de  $a_1 \dots a_k$ .

Suponga que  $w_1 \dots w_i$  es sufijo de  $w_1 \dots w_{\max(S)}$ .

Como  $w_1 \dots w_i$  es sufijo de  $w_1 \dots w_{\max(S)}$  y  $w_1 \dots w_{\max(S)}$  es sufijo de  $u$ ,  
entonces  $w_1 \dots w_i$  es sufijo de  $u = a_1 \dots a_k$ .

Por la "Propiedad", concluimos que  $i \in S$ .

## Autómata finito con $k$ -lookahead

Sea  $\Sigma$  un alfabeto finito.

### Definiciones

Se definen los siguientes conjuntos de palabra:

- $\Sigma_{\blacksquare} = \Sigma^* \times \Sigma^*$
- $\Sigma_{\blacksquare}^k = \{(u, v) \in \Sigma_{\blacksquare} \mid |uv| = k\}$

### Notación

En vez de  $(u, v) \in \Sigma_{\blacksquare}$ , escribiremos  $u.v \in \Sigma_{\blacksquare}$ .

## Definición

Un autómata finito determinista con  $k$ -lookahead es:

$$\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$$

- $Q$  es un conjunto finito de estados.
- $\Sigma$  es el alfabeto de input.
- $q_0$  es el estado inicial.
- $F \subseteq Q$  es el conjunto de estados finales.


+

- $\delta: Q \times (\Sigma \cup \{\$\})^k \rightarrow Q$  es una función parcial, tal que:

\$ ≈ End Of String

Para todo  $p \in Q$  y  $w \in (\Sigma \cup \{\$\})^k$ :  $|\{u.v \mid \delta(p, u.v) = q \text{ y } uv = w\}| \leq 1$

Algunos ejemplos:



Sea  $\mathcal{A} = (Q, \Sigma, \delta, q_0, F)$  un DFA con  $k$ -lookahead.

## Definiciones:

- Un par  $(q, w) \in Q \times (\Sigma \cup \{\$\})^*$  es una **configuración** de  $\mathcal{A}$ .
- Una configuración  $(q_0, w\$^k)$  es **inicial**.
- Una configuración  $(q, \$^k)$  es **final** si  $q \in F$ .

El sufijo  $\$^k$  nos sirve para marcar el final del input (y simplificar la definición de lookahead al leer el final de la palabra)

## Definiciones

- Se define la relación  $\vdash_{\mathcal{A}}$  de **siguiente-paso** entre configuraciones de  $\mathcal{A}$ :

$$(p_1, w_1) \vdash_{\mathcal{A}} (p_2, w_2)$$

si, y solo si,  $\delta(p_1, u.v) = p_2$  y existe  $w \in \Sigma^*$  tal que  $w_1 = uvw$  y  $w_2 = vw$ .

- $\mathcal{A}$  **acepta**  $w$  si existe una configuración **inicial**  $(q_0, w\$^k)$  y una configuración **final**  $(q_f, \$^k)$  tal que:

$$(q_0, w\$^k) \vdash_{\mathcal{A}}^* (q_f, \$^k)$$

- Llamaremos un **lazy autómeta** a un DFA con 1-lookahead.

## Algoritmo de Knuth-Morris-Prat

Sea  $w = w_1 \dots w_m$  y  $\mathcal{A}_w^{det} = (Q^{det}, \Sigma, \delta^{det}, \{0\}, F^{det})$  la determinización de  $\mathcal{A}_w$ .

### Definición

Para  $i \in [0, m]$ , sea  $S_i$  el **único estado** en  $Q^{det}$  tal que  $i = \max(S_i)$ .

### Propiedad 2


Para todo  $a \in \{w_1, \dots, w_m\}$  y  $i \in [0, m-1]$ :

- $S_i - \{i\} \in Q^{det}$ .
- $a = w_{i+1}$ , entonces  $\delta^{det}(S_i, a) = S_{i+1}$ .
- $a \neq w_{i+1}$ , entonces  $\delta^{det}(S_i, a) = \delta^{det}(S_i - \{i\})$ .

### Construcción

Se define el lazy autómeta  $\mathcal{A}_w^{lazy} = (Q^{det}, \Sigma, \delta^{lazy}, \{0\}, F^{det})$  tal que:

- Para todo  $a \neq w_1$ :  $\delta^{lazy}(\{0\}, a) = \{0\}$ .
- Para todo  $a \in \{w_1, \dots, w_m\}$  y  $i \in [0, m-1]$ :
  - Si  $a = w_{i+1}$ , entonces  $\delta^{lazy}(S_i, a) = S_{i+1}$ .
  - Si  $a \neq w_{i+1}$  y  $i \neq 0$ , entonces  $\delta^{lazy}(S_i, a) = S_i - \{i\}$ .



¿Cuántos pasos toma  $\mathcal{A}_w^{lazy}$  sobre un documento  $d$ ?

- Número de pasos que  $\mathcal{A}_w^{lazy}$  **consume** letras =  $|d|$
- Número de pasos que  $\mathcal{A}_w^{lazy}$  **retrocede**  $\leq d$
- Número de **pasos totales** de  $\mathcal{A}_w^{lazy} \leq 2 \cdot |d|$

## Gramáticas libres de contexto

Una **gramática libre de contexto** (CFG) es una tupla:

$$\mathcal{G} = (V, \Sigma, P, S)$$

- $V$  es un conjunto finito de **variables** o **no-terminales**.
- $\Sigma$  es un alfabeto finito (o **terminales**) tal que  $\Sigma \cap V = \emptyset$ .
- $P \subseteq V \times (V \cup \Sigma)^*$  es un subconjunto finito de **reglas** o **producciones**.
- $S \in V$  es la **variable inicial**.

Ejemplo:

$$\begin{array}{lcl} \mathcal{G}: & A & \rightarrow 0 A 1 \\ & A & \rightarrow B \\ & B & \rightarrow \# \end{array}$$

La gramática se define como  $\mathcal{G} = (V, \Sigma, P, S)$  tal que:

- $V = \{ A, B \}$  → Variables en **mayus**
- $\Sigma = \{ 0, 1, \# \}$  → Letras en **minus**
- $P = \{ A \rightarrow 0A1, A \rightarrow B, B \rightarrow \# \}$  → **Producciones**
- $S = A$

**Notación:**

- Para las **variables** en una gramática usaremos letras mayúsculas:  
 $A, B, C, \dots$
- Para los **terminales** en una gramática usaremos letras minúsculas.  
 $a, b, c, \dots$
- Para palabras en  $(V \cup \Sigma)^*$  usaremos símbolos:  
 $\alpha, \beta, \gamma, \dots$
- Para una producción  $(A, \alpha) \in P$  la escribimos como:  
 $A \rightarrow \alpha$

## Simplificación

Si tenemos un conjunto de reglas de la forma:

$$\begin{array}{l} A \rightarrow \alpha_1 \\ A \rightarrow \alpha_2 \\ \dots \\ A \rightarrow \alpha_n \end{array}$$

entonces escribimos estas reglas **sucintamente** como:

$$A \rightarrow \alpha_1 \mid \alpha_2 \mid \dots \mid \alpha_n$$

(recordar que:  $\alpha_1, \alpha_2, \dots, \alpha_n \in (\Sigma \cup V)^*$ )

Ejemplo anterior:

$$\mathcal{G}: \begin{array}{l} A \rightarrow 0 A 1 \\ A \rightarrow B \\ B \rightarrow \# \end{array}$$

Notación sucinta:

$$\mathcal{G}: \begin{array}{l} A \rightarrow 0 A 1 \mid B \\ B \rightarrow \# \end{array}$$

## Producciones

Sea  $\mathcal{G} = (V, \Sigma, P, S)$  una CFG.

**Definición:**

Definimos la relación  $\Rightarrow \subseteq (V \cup \Sigma)^* \times (V \cup \Sigma)^*$  de **producción** tal que:

$$\alpha \cdot A \cdot \beta \Rightarrow \alpha \cdot \gamma \cdot \beta \quad \text{si, y solo si,} \quad (A \rightarrow \gamma) \in P$$

para todo  $A \in V$  y  $\alpha, \beta, \gamma \in (V \cup \Sigma)^*$

Si  $\alpha A \beta \Rightarrow \alpha \gamma \beta$  entonces decimos que:

- $\alpha A \beta$  **produce**  $\alpha \gamma \beta$  o
- $\alpha \gamma \beta$  **es producible** desde  $\alpha A \beta$ .

$\alpha A \beta \Rightarrow \alpha \gamma \beta$  es reemplazar  $\gamma$  en  $A$  en la palabra  $\alpha A \beta$ .

¿Cuál de las siguientes producciones son correctas?

$$\mathcal{G}: \begin{array}{lcl} A & \rightarrow & 0 A 1 \mid B \\ B & \rightarrow & \# \end{array}$$

- $A \Rightarrow B$  **SI**
- $00A11 \Rightarrow 000A111$  **SI**
- $000B111 \Rightarrow 000A111$  **NO**
- $0A0A1B \underset{0A1}{\underbrace{A}} \Rightarrow 0A0A1B0A1$  **SI**

### Definición

Dada dos palabras  $\alpha, \beta \in (V \cup \Sigma)^*$  decimos que  $\alpha$  **deriva**  $\beta$ :

$$\alpha \Rightarrow^* \beta$$

Si existe  $\alpha_1, \alpha_2, \dots, \alpha_n \in (V \cup \Sigma)^*$  tal que:

$$\alpha \Rightarrow \alpha_1 \Rightarrow \alpha_2 \Rightarrow \dots \Rightarrow \beta$$

con  $\Rightarrow^*$  es la clausura refleja y transitiva de  $\Rightarrow$ , esto es:

1.  $\alpha \Rightarrow^* \alpha$
2.  $\alpha \Rightarrow^* \beta$  si, y solo si, existe  $\gamma$  tal que  $\alpha \Rightarrow^* \gamma$  y  $\gamma \Rightarrow \beta$  para todo  $\alpha, \beta \in (V \cup \Sigma)^*$ .

Notar que  $\Rightarrow$  y  $\Rightarrow^*$  son relaciones entre palabras en  $(V \cup \Sigma)^*$

¿Cuál de las siguientes derivaciones son correctas?

$$\mathcal{G}: \begin{array}{lcl} A & \rightarrow & 0 A 1 \mid B \\ B & \rightarrow & \# \end{array}$$

- $A \Rightarrow^* 000A111$  **SI**
- $00A11 \Rightarrow^* 000B111$  **NO**
- $00A11 \Rightarrow^* 000\#111$  **SI**

### Definición

El lenguaje de una gramática  $\mathcal{G}$  se define como:

$$\mathcal{L}(\mathcal{G}) = \{ w \in \Sigma^* \mid S \Rightarrow^* w \}$$

$\mathcal{L}(\mathcal{G})$  son todas las palabras en  $\Sigma^*$  que se pueden derivar desde  $S$



¿Qué palabras están en  $\mathcal{L}(\mathcal{G})$ ?

$$\begin{array}{lcl} \mathcal{G}: & A & \rightarrow 0A1 \mid B \\ & B & \rightarrow \# \end{array}$$

- Como  $A \Rightarrow^* 000\#111$ , entonces  $000\#111 \in \mathcal{L}(\mathcal{G})$ .
- En general, uno puede demostrar por inducción que:

$$\mathcal{L}(\mathcal{G}) = \{ 0^n \# 1^n \mid n \geq 0 \}$$

¿Qué lenguaje define cada gramática libre de contexto?

$$\begin{array}{lcl} 1. \mathcal{G}: & S & \rightarrow AS \mid \epsilon \\ & A & \rightarrow aa \mid ab \mid ba \mid bb \end{array}$$

Palabras de largo par

$$\begin{array}{lcl} 2. \mathcal{G}: & S & \rightarrow S + S \mid S \times S \mid (S) \mid A \\ & A & \rightarrow 0 \mid 1 \mid \dots \mid 9 \end{array}$$

Todas las expresiones aritméticas válidas del 0 al 9

$$3. \mathcal{G}: S \rightarrow aSb \mid SS \mid \epsilon$$

Si reemplazo ' $a$ ' y ' $b$ ' por ' $($ ' y ' $)$ ' reespectivamente, el lenguaje corresponde al conjunto de paréntesis bien anidados (es decir, paréntesis puestos de manera correcta)

¿Cuál es una gramática para cada lenguaje?

$$1. L_1 = \{ 0^n 1^n \mid n \geq 0 \} \cup \{ 1^n 0^n \mid n \geq 0 \}$$

$$2. L_2 = \{ w \in \{a, b\}^* \mid w = w^{\text{rev}} \}$$

$$\begin{array}{l} 1. \\ S \rightarrow A \mid B \\ A \rightarrow 0A1 \mid \epsilon \\ B \rightarrow 1B0 \mid \epsilon \end{array}$$

$$2. S \rightarrow aSa \mid bSb \mid a \mid b \mid \epsilon$$

### Definición

Diremos que  $L \subseteq \Sigma^*$  es un **lenguaje libre de contexto** ssi existe una gramática libre de contexto  $\mathcal{G}$  tal que:

$$L = \mathcal{L}(\mathcal{G})$$

Ejemplos:

- $L = \{ 0^n \# 1^n \mid n \geq 0 \}$
- $Par = \{ w \in \{a, b\}^* \mid w \text{ tiene largo par} \}$
- $Pal = \{ w \in \{a, b\}^* \mid w = w^{\text{rev}} \}$

## Árboles ordenados y etiquetados

### Definiciones

El conjunto de **árboles ordenados y etiquetados** (o solo **árboles**) sobre etiquetas  $\Sigma$  y  $V$ , se define recursivamente como:

- $t := a$  es un árbol para todo  $a \in \Sigma$ .
- Si  $t_1, \dots, t_k$  son árboles,  
Entonces  $t := A(t_1, \dots, t_k)$  es un árbol para todo  $A \in V$ .

Para un árbol  $t := A(t_1, \dots, t_k)$  cualquiera se define:

- $\text{raiz}(t) = A$
- $\text{hijos}(t) = t_1, \dots, t_k$

Si  $t = a$ , entonces decimos que  $t$  es una hoja,  $\text{raiz}(t) = a$  y  $\text{hijos}(t) = \epsilon$ .

### Definiciones

Se define el conjunto de **árboles de derivación** recursivamente como:

- Si  $a \in \Sigma$ , entonces  $t = a$  es un árbol de derivación.
- Si  $A \rightarrow A_1 \dots A_k \in P$  y  
 $t_1, \dots, t_k$  son árboles de derivación con  $\text{raiz}(t_i) = A_i$  para todo  $i \leq k$  entonces  
 $t = A(t_1, \dots, t_k)$  es un árbol de derivación.

Decimos que  $t$  es un **árbol de derivación de  $\mathcal{G}$**  si:


1.  $t$  es un árbol de derivación y
2.  $\text{raiz}(t) = S$

Los árboles de derivación son todos los árboles que parten desde  $S$

Ejemplo de árbol de derivación

$$\mathcal{G}: \quad E \rightarrow E + E \mid E * E \mid n$$

Algunos **árboles de derivación** para  $\mathcal{G}$ :



## Definiciones

Se define la función **yield** sobre árboles, recursivamente como:

- Si  $t = a \in \Sigma$ , entonces  $\text{yield}(t) = a$ .
- Si  $t$  no es una hoja e  $\text{hijos}(t) = t_1 t_2 \dots t_k$  entonces:

$$\text{yield}(t) = \text{yield}(t_1) \cdot \text{yield}(t_2) \cdot \dots \cdot \text{yield}(t_k)$$

Decimos que  $t$  es un **árbol de derivación de  $\mathcal{G}$  para  $w$**  si:

1.  $t$  es un árbol de derivación de  $\mathcal{G}$  y
2.  $\text{yield}(t) = w$ .

Las hojas de  $t$  forman la palabra  $w$

## Proposición

$w \in \mathcal{L}(\mathcal{G})$  si, y solo si, existe un árbol de derivación de  $\mathcal{G}$  para  $w$ .

Un árbol de derivación es la representación gráfica de una derivación

Ejemplo:

$E \rightarrow E + E \mid E * E \mid n$

- 1)  $E \Rightarrow E * E \Rightarrow E + E * E \Rightarrow n + E * E \Rightarrow n + n * E \Rightarrow n + n * n$
- 2)  $E \Rightarrow E * E \Rightarrow E + E * E \Rightarrow E + n * E \Rightarrow E + n * n \Rightarrow n + n * n$
- 3)  $E \Rightarrow E * E \Rightarrow E + E * E \Rightarrow E + E * n \Rightarrow E + n * n \Rightarrow n + n * n$
- 4)  $E \Rightarrow E * E \Rightarrow E * n \Rightarrow E + E * n \Rightarrow n + E * n \Rightarrow n + n * n$
- 5)  $E \Rightarrow E * E \Rightarrow E * n \Rightarrow E + E * n \Rightarrow E + n * n \Rightarrow n + n * n$
- 6) ...

Dado un árbol de derivación, ¿Con cuál nos quedamos?

## Definición

- Definimos la **derivación por la izquierda**  $\Rightarrow_{lm} \subseteq (V \cup \Sigma)^* \times (V \cup \Sigma)^*$ :

$$w \cdot A \cdot \beta \Rightarrow_{lm} w \cdot \gamma \cdot \beta \quad \text{si, y solo si,} \quad A \rightarrow \gamma \in P$$

para todo  $A \in V, w \in \Sigma^*$  y  $\beta, \gamma \in (V \cup \Sigma)^*$ .

- Definimos la derivación por la derecha  $\Rightarrow_{rm} \subseteq (V \cup \Sigma)^* \times (V \cup \Sigma)^*$ :

$$\alpha \cdot A \cdot w \Rightarrow_{rm} \alpha \cdot \gamma \cdot w \quad \text{si, y solo si,} \quad A \rightarrow \gamma \in P$$


para todo  $A \in V, w \in \Sigma^*$  y  $\alpha, \gamma \in (V \cup \Sigma)^*$ .

Se define  $\Rightarrow_{lm}^*$  y  $\Rightarrow_{rm}^*$  como la clausura refleja y transitiva de  $\Rightarrow_{lm}$  y  $\Rightarrow_{rm}$ , respectivamente.

$\Rightarrow_{lm}^*$  y  $\Rightarrow_{rm}^*$  solo reemplaza a la **izquierda** (leftmost) y **derecha** (rightmost)

Ejemplo anterior:

$$E \rightarrow E + E \mid E * E \mid n$$



### Derivación por la izquierda (lm)

$$E \Rightarrow_{lm} E * E \Rightarrow_{lm} E + E * E \Rightarrow_{lm} n + E * E \Rightarrow_{lm} n + n * E \Rightarrow_{lm} n + n * n$$

### Derivación por la derecha (rm)

$$E \Rightarrow_{rm} E * E \Rightarrow_{rm} E * n \Rightarrow_{rm} E + E * n \Rightarrow_{rm} E + n * n \Rightarrow_{rm} n + n * n$$

¿Cuál es la relación entre el **tipo de derivación** y el **recorrido del árbol**?

### Sabemos que...

- Por cada derivación, existe un único árbol de derivación.
- Por cada árbol de derivación existen **múltiples** posibles derivaciones.

### Proposición

Por cada árbol de derivación, existe una **única** derivación por la izquierda y una **única** derivación por la derecha.

### Simplificación de gramáticas

#### Variables inútiles

Sea  $\mathcal{G} = (V, \Sigma, P, S)$  una CFG.

#### Definición

Diremos que una variable  $X \in V$  es **útil** si existe una derivación:

$$S \Rightarrow^* \alpha X \beta \Rightarrow^* w$$

Al contrario, diremos que una variable  $X$  es **inútil** si NO es útil.

¿Qué variables son inútiles?

$$\begin{aligned} S &\rightarrow aAa \mid aBC \\ A &\rightarrow aS \mid bD \\ B &\rightarrow aBa \mid b. \\ C &\rightarrow abb \mid DD. \\ D &\rightarrow aDa \end{aligned}$$

**D:** Una vez obtengo una  $D$ , no puedo llegar a nada.

#### Definición

Para una variable  $X \in V$ :

1. Decimos que  $X$  es **alcanzable** si existe una derivación:

$$S \Rightarrow^* \alpha X \beta$$

2. Decimos que  $X$  es **generadora** si existe una derivación:

$$X \Rightarrow^* w$$

## Propiedad

Para toda variable  $X \in V$ :

Existe una regla  $X \rightarrow \alpha$  tal que todas las variables en  $\alpha$  son generadoras  
si y solo si,  $X$  es **generadora**.

¿Cuáles variables son generadoras?

$S \rightarrow aAa \mid aBD$   
 $A \rightarrow aB \mid bD$   
 $B \rightarrow aBa \mid b$   
 $C \rightarrow abb \mid DD$   
 $D \rightarrow aDca$

$G_0 = \{B, C\}$   
 $G_1 = \{A\}$   
 $G_2 = \{S\}$   
 $G = \{A, B, C, S\}$

## Propiedad

Para toda variable  $X \in V - \{S\}$ :

Existe una producción  $Y \rightarrow \alpha X \beta$  en  $P$  tal  
que  $Y \in V$  es alcanzable  
si, y solo si,  $X$  es **alcanzable**.

¿Cuáles variables son alcanzables?

$S \rightarrow aAa$   
 $A \rightarrow aB$   
 $B \rightarrow aBa \mid b$   
 $C \rightarrow abb$

$C_0 = \{S\}$	$C_0 = \{A\}$	$C_0 = \{B\}$	$C_0 = \emptyset$
$C = \emptyset$	$C = \{S\}$	$C = \{S, A\}$	$C = \{S, A, B\}$

## Teorema

Sea  $\mathcal{G}''$  una gramática creada a partir de  $\mathcal{G}$  después de:

- Eliminar todas las variables y reglas **NO generadoras**.
- Eliminar todas las variables y reglas **NO alcanzables**.

Entonces,  $\mathcal{L}(\mathcal{G}'') = \mathcal{L}(\mathcal{G})$  y  $\mathcal{G}''$  no contiene variables inútiles.

**input** : Gramática  $\mathcal{G} = (V, \Sigma, P, S)$

**output**: Conjunto  $G$  de variables generadoras

**Function** Generadores ( $\mathcal{G}$ )

let  $G_0 := \{X \in V \mid (X \rightarrow w) \in P\}$

let  $G := \emptyset$

while  $G_0 \neq G$  do

$G := G_0$

    foreach  $(X \rightarrow \alpha) \in P$  do

        if todas las variables en  $\alpha$  estan en  $G$  then

$G_0 := G_0 \cup \{X\}$

return  $G$

**input** : Gramática  $\mathcal{G} = (V, \Sigma, P, S)$

**output**: Conjunto  $C$  de variables alcanzables

**Function** alcanzables ( $\mathcal{G}$ )

let  $C_0 := \{S\}$

let  $C := \emptyset$

while  $C_0 \neq \emptyset$  do

    take  $Y \in C_0$

$C_0 := C_0 - \{Y\}$

$C := C \cup \{Y\}$

    foreach  $X \in V - C$  tal que existe una regla  $(Y \rightarrow \alpha X \beta) \in P$  do

$C_0 := C_0 \cup \{X\}$

return  $C$

### Demostración

Sea  $\mathcal{G} = (V, \Sigma, P, S)$  una CFG.

Sea  $\mathcal{G}' = (V', \Sigma, P', S)$  al eliminar las variables **no generadoras** de  $\mathcal{G}$ :

$$V' = \{ X \in V \mid \exists w. X \xRightarrow[\mathcal{G}]{*} w \}$$

$$P' = \{ X \rightarrow \alpha \in P \mid X \in V' \wedge \alpha \in (V' \cup \Sigma)^* \}$$

Sea  $\mathcal{G}'' = (V'', \Sigma, P'', S)$  al eliminar las variables **no alcanzables** de  $\mathcal{G}'$ :

$$V'' = \{ X \in V' \mid \exists \alpha, \beta. S \xRightarrow[\mathcal{G}']{*} \alpha X \beta \}$$

$$P'' = \{ X \rightarrow \alpha \in P' \mid X \in V'' \wedge \alpha \in (V'' \cup \Sigma)^* \}$$

Considere las propiedades de  $\mathcal{G}, \mathcal{G}', \mathcal{G}''$ .

1. Para todo  $a \in (V \cup \Sigma)^*$ , si  $\alpha \xRightarrow[\mathcal{G}]{*} w$  entonces  $\alpha \xRightarrow[\mathcal{G}']{*} w$ .
2. Para todo  $a \in (V' \cup \Sigma)^*$ , si  $S \xRightarrow[\mathcal{G}']{*} \alpha$  entonces  $S \xRightarrow[\mathcal{G}'']{*} \alpha$ .
3. Para todo  $a \in (V'' \cup \Sigma)^*$ , si  $\alpha \xRightarrow[\mathcal{G}']{*} w$  entonces  $\alpha \xRightarrow[\mathcal{G}'']{*} w$ .

### Demostración

**PD:**  $\mathcal{L}(\mathcal{G}'') = \mathcal{L}(\mathcal{G})$ .

Como  $V'' \subseteq V$  y  $P'' \subseteq P$ , entonces  $\mathcal{L}(\mathcal{G}'') \subseteq \mathcal{L}(\mathcal{G})$ .

**PD:**  $\mathcal{L}(\mathcal{G}) = \mathcal{L}(\mathcal{G}'')$ .

Sea  $w \in \mathcal{L}(\mathcal{G})$  tal que  $S \xRightarrow[\mathcal{G}]{*} w$ .

- Por la propiedad 1. tenemos que  $S \xRightarrow[\mathcal{G}']{*} w$ .
- Por la propiedad 2. tenemos que  $S \xRightarrow[\mathcal{G}'']{*} w$ .

Por lo tanto  $w \in \mathcal{L}(\mathcal{G}'')$  y concluimos que  $\mathcal{L}(\mathcal{G}) \subseteq \mathcal{L}(\mathcal{G}'')$ .

## Demostración

**PD:** Para todo  $X \in V''$ ,  $X$  es útil en  $\mathcal{G}''$ .

Como  $X \in V''$ , entonces  $S \xRightarrow[\mathcal{G}']{*} \alpha X \beta$  para algún  $\alpha, \beta \in (V' \cup \Sigma)^*$ .

Por la propiedad 2. se tiene que  $S \xRightarrow[\mathcal{G}'']{*} \alpha X \beta$  y  $\alpha, \beta \in (V'' \cup \Sigma)^*$ .

Como  $X \in V''$  y  $\alpha, \beta \in (V' \cup \Sigma)^*$ , entonces existen  $u, v, w$  tal que:

$$\alpha \xRightarrow[\mathcal{G}']{*} u, \quad X \xRightarrow[\mathcal{G}']{*} v, \quad \beta \xRightarrow[\mathcal{G}']{*} w$$

Por la propiedad 1. se tiene que:  $\alpha \xRightarrow[\mathcal{G}']{*} u, X \xRightarrow[\mathcal{G}']{*} v, \beta \xRightarrow[\mathcal{G}']{*} w$ .

Por la propiedad 3. se tiene que:  $\alpha \xRightarrow[\mathcal{G}'']{*} u, X \xRightarrow[\mathcal{G}'']{*} v, \beta \xRightarrow[\mathcal{G}'']{*} w$ .

Juntando todo  $S \xRightarrow[\mathcal{G}'']{*} \alpha X \beta \xRightarrow[\mathcal{G}'']{*} uvw$  y  $X$  es útil en  $\mathcal{G}''$ .

**¿Qué falla al eliminar primero las no alcanzables y después las no generadoras?**

Ejemplo:

$$\begin{array}{lcl} \mathcal{G}: & S & \rightarrow AB \mid b \\ & A & \rightarrow a \\ & B & \rightarrow B \end{array}$$

Al eliminar variables **no alcanzables** en  $\mathcal{G}$ :

$$\mathcal{G}': \begin{array}{lcl} S & \rightarrow & AB \mid b \\ A & \rightarrow & a \\ B & \rightarrow & B \end{array}$$

Al eliminar variables **no generadoras** en  $\mathcal{G}'$ :

$$\mathcal{G}'': \begin{array}{lcl} S & \rightarrow & b \\ A & \rightarrow & a \end{array}$$



( $A$  es inútil)



## Definición

- Decimos que una producción de la forma:  $X \rightarrow \epsilon$  es **en vacío**.
- Decimos que una producción de la forma:  $X \rightarrow Y$  es **unitaria**.

Deseamos eliminar este tipo de producciones.

## Conclusión

Si  $\epsilon \in \mathcal{L}(\mathcal{G})$ , entonces

NO se pueden borrar las producciones en vacío sin alterar el lenguaje  $\mathcal{G}$ .

Desde ahora, supondremos que  $\epsilon \notin \mathcal{L}(\mathcal{G})$ .

Sea  $\mathcal{G} = (V, \Sigma, P, S)$  un CFG tal que  $\epsilon \notin \mathcal{L}(\mathcal{G})$ .

## Observación

Suponga las reglas  $X \rightarrow Y$  y  $Y \rightarrow \gamma$  en  $P$ .

- Si  $\mathcal{G}' = (V, \Sigma, P \cup \{X \rightarrow \gamma\}, S)$   $\mathcal{L}(\mathcal{G}') = \mathcal{L}(\mathcal{G})$ ? **SI**
- Si  $\mathcal{G}'' = (V, \Sigma, P \cup \{X \rightarrow \gamma\} - \{X \rightarrow Y\}, S)$   $\mathcal{L}(\mathcal{G}'') = \mathcal{L}(\mathcal{G})$ ? **NO**

Suponga las reglas  $X \rightarrow \epsilon$  y  $Z \rightarrow \alpha X \beta$  en  $P$ .

- Si  $\mathcal{G}' = (V, \Sigma, P \cup \{Z \rightarrow \alpha \beta\}, S)$   $\mathcal{L}(\mathcal{G}') = \mathcal{L}(\mathcal{G})$ ? **SI**
- Si  $\mathcal{G}'' = (V, \Sigma, P \cup \{Z \rightarrow \alpha \beta\} - \{X \rightarrow \epsilon\}, S)$   $\mathcal{L}(\mathcal{G}'') = \mathcal{L}(\mathcal{G})$ ? **NO**

## Clausura de producciones unitarias y en vacío

Sea  $P^*$  el **menor conjunto de producciones** que contiene  $P$  y **cerrado bajo** las siguientes reglas:

1. Si  $X \rightarrow Y \in P^*$  y  $Y \rightarrow \gamma \in P^*$ , entonces  $X \rightarrow \gamma \in P^*$ .
2. Si  $X \rightarrow \epsilon \in P^*$  y  $Z \rightarrow \alpha X \beta \in P^*$ , entonces  $Z \rightarrow \alpha \beta \in P^*$ .

Defina  $\mathcal{G}^* = (V, \Sigma, P^*, S)$ . Entonces:

- $P^*$  es infinito.
- $\mathcal{L}(\mathcal{G}^*) = \mathcal{L}(\mathcal{G})$

## ¿Cómo eliminamos las producciones en vacío y unitarias?

Para cualquier palabra  $w \in \mathcal{L}(\mathcal{G}^*)$ ,

Sea  $\mathcal{T}$  un árbol de derivación de  $w$  en  $\mathcal{G}^*$  de **tamaño mínimo**.

### Propiedad 1


El árbol de derivación  $\mathcal{T}$  NO usa una **producción unitaria**.

### Propiedad 2

El árbol de derivación  $\mathcal{T}$  NO usa una producción **en vacío**.


#### Demostración (por contradicción)

Suponemos que  $\mathcal{T}$  usa una producción unitaria:



#### Demostración (por contradicción)

Suponemos que  $\mathcal{T}$  usa una producción en vacío:



Por la **Propiedad 1** y **Propiedad 2** tenemos que:

Para todo  $w \in \mathcal{L}(\mathcal{G}^*)$ , existe una derivación de  $w$  en  $\mathcal{G}$  que NO usa producciones **en vacío** ni producciones **unitarias**.

Podemos eliminar las producciones en vacío y unitarias de  $\mathcal{G}^*$ !

### Teorema

Para toda CFG  $\mathcal{G}$  tal que  $\epsilon \notin \mathcal{L}(\mathcal{G})$ , sea:

- $\mathcal{G}^*$  la clausura de producciones unitarias y en vacío.
- $\hat{\mathcal{G}}$  el resultado de remover toda producción unitaria o en vacío de  $\mathcal{G}^*$ .

Entonces  $\mathcal{L}(\hat{\mathcal{G}}) = \mathcal{L}(\mathcal{G})$  y  $\hat{\mathcal{G}}$  no tiene producciones unitarias o en vacío.

Para eliminar las producciones en vacío o unitarias de  $\mathcal{G}$ :

- Construimos  $\mathcal{G}^*$  haciendo la clausura de producción unitarias y en vacío,
- Construimos  $\hat{\mathcal{G}}$  removiendo todas las producciones unitarias o en vacío de  $\mathcal{G}^*$ .

Por el resultado anterior sabemos que  $\mathcal{L}(\mathcal{G}) = \mathcal{L}(\hat{\mathcal{G}})$ .

## Forma Normal de Chomsky

### Definición

Una gramática  $\mathcal{G}$  esta en la **forma normal de Chomsky** (CNF) si todas sus reglas son de la forma:

- $X \rightarrow YZ$
- $X \rightarrow a$

### Toda gramática se puede convertir en CNF

Sea  $\mathcal{G} = (V, \Sigma, P, S)$  una CFG tal que  $\epsilon \notin \mathcal{L}(\mathcal{G})$ .

- Primero, suponga que  $\mathcal{G}$  no contiene las reglas en vacío o unitarias.
- Por lo tanto, todas las reglas en  $\mathcal{G}$  son de la forma:
  - $X \rightarrow \gamma$  para  $|\gamma| \geq 2$
  - $X \rightarrow a$

Paso 1: Convertir todas las reglas a la forma:

- $X \rightarrow Y_1 Y_2 \dots Y_k$  para  $k \geq 2$
- $X \rightarrow a$

¿Cómo?

- Para cada  $a \in \Sigma$ , agregar una nueva variable  $X_a$  y una regla  $X_a \rightarrow a$ .
- Reemplazar todas las ocurrencias antiguas de  $a$  por  $X_a$ .

Paso 2: Convertir todas las reglas a la forma:

- $X \rightarrow YZ$
- $X \rightarrow a$

¿Cómo?

Para cada regla  $p: X \rightarrow Y_1 Y_2 \dots Y_k$  con  $k \geq 3$ :

- Agregamos una **nueva** variable  $Z$ .
- Reemplazamos la regla  $p$  por **dos reglas**:

$$X \rightarrow Y_1 Z \quad \wedge \quad Z \rightarrow Y_2 \dots Y_k$$

**Repetimos** este paso.

## Lema de Bombeo Para lenguajes libres de contexto

Sea  $L \subseteq \Sigma^*$ . Si  $L$  es **libre de contexto**, entonces:

**Existe** un  $N > 0$  tal que

**Para toda** palabra  $z \in L$  con  $|z| \geq N$

**Existe** una descomposición  $z = uvwxy$

Con  $vx \neq \epsilon$  y  $|vwx| \leq N$  tal que

**Para todo**  $i \geq 0$ ,  $u \cdot v^i \cdot w \cdot x^i \cdot y \in L$ .

**Contra-positivo:**

Sea  $L \subseteq \Sigma^*$ . Si

**Para todo**  $N > 0$  tal que

**Existe** una palabra  $z \in L$  con  $|z| \geq N$

**Para toda** descomposición  $z = uvwxy$

Con  $vx \neq \epsilon$  y  $|vwx| \leq N$  tal que

**Existe**  $i \geq 0$ ,  $u \cdot v^i \cdot w \cdot x^i \cdot y \notin L$ .

entonces  $L$  **NO** es libre de contexto.

Jugando contra un demonio (  $a^{n^2}$  )



" $L$  NO es CFL"



" $L$  es CFL"

El escoge un  $N > 0$

Uno escoge  $z \in L$  con  $|z| \geq N$

El escoge  $uvwxxy = z$  con  $vx \neq \epsilon$  y  $|vwx| \leq N$

Uno escoge  $i \geq 0$

Uno gana si  $u \cdot v^i \cdot w \cdot x^i \cdot y \notin L$

El gana si  $u \cdot v^i \cdot w \cdot x^i \cdot y \in L$



" $a^{n^2}$  NO es CFL"



" $a^{n^2}$  es CFL"

Escojo  $N > 0$

Yo escojo  $a^{N^2} \in L$

Entonces escojo  $\underbrace{a^j}_{u} \underbrace{a^k}_{v} \underbrace{a^l}_{w} \underbrace{a^m}_{x} \underbrace{a^n}_{y} = a^{N^2}$

con  $k + m \neq 0$  y  $k + l + m \leq N$

Yo escojo  $i = 2$

Jugando contra un demonio ( $a^n b^n c^n$ )



" $a^n b^n c^n$  NO es CFL"



" $a^n b^n c^n$  es CFL"

Escojo  $N > 0$

Yo escojo  $a^N b^N c^N \in L$

Entonces escojo  $uvwxxy = a^N b^N c^N$  con  $vx \neq \epsilon$  y  $|vwx| \leq N$

Yo escojo  $i = 2$

Como  $uvwxxy = a^N b^N c^N$  con  $vx \neq \epsilon$  y  $|vwx| \leq N$ , entonces:

$vwx \in \mathcal{L}(a^+ b^+)$  o  $vwx \in \mathcal{L}(b^+ c^+)$

¿ por qué ?

■ Si  $vwx \in \mathcal{L}(a^+ b^+)$ , entonces:

- $|u v^2 w x^2 y|_{a,b} > 2N$
- $|u v^2 w x^2 y|_c = N$

por lo tanto  $z' \notin L$ .

■ Si  $vwx \in \mathcal{L}(b^+ c^+)$ , entonces:

- $|u v^2 w x^2 y|_{b,c} > 2N$
- $|u v^2 w x^2 y|_a = N$

por lo tanto  $z' \notin L$ .

En ambos casos,  $uv^2wx^2y \notin L$